

Radyomik Özelliklerle Papilödem Tespiti: Makine Öğrenmesi Pipeline'ı

Ders	Makine Öğrenmesi
Ödev Türü	Final Projesi
Problem	İkili Sınıflandırma (Normal vs Papilödem)
Yöntem	Soft Voting Ensemble + Optuna + MRMR
Veri Seti	69 hasta, 966 ROI, 746 radyomik özellik
GitHub	github.com/barisaykent-spec/papilodema-classification

ÖZET

Bu çalışmada 69 hastadan (48 Normal, 21 Papilödem) elde edilen 966 ROI bileşeni ve 746 radyomik özellik kullanılarak papilödem tespiti için kapsamlı bir makine öğrenmesi pipeline'ı geliştirilmiştir. MRMR özellik seçimi ile 746 özellik 10'a indirilmiş, Optuna hiperparametre optimizasyonu ile Random Forest, Extra Trees ve Gradient Boosting modelleri eğitilmiştir. Soft Voting Ensemble ve Sigmoid kalibrasyon sonucunda hasta bazında ROC-AUC=0.933, Macro F1=0.899 ve Precision=1.000 elde edilmiştir. Friedman testi ile modeller arasında istatistiksel anlamlı fark saptanmış ($p=0.021$); Wilcoxon + Bonferroni analizi RF'nin GB'ye göre anlamlı üstünlüğünü ortaya koymuştur ($p=0.046$).

1. Giriş

Papilödem, optik sinir başının şişmesiyle karakterize ve genellikle intrakraniyal basınç artışına işaret eden kritik bir oftalmolojik bulgudur. Erken ve doğru tespiti, altta yatan hayati tehlike taşıyan durumların önlenmesi açısından büyük önem taşımaktadır.

Radyomik analiz, tıbbi görüntülerden yüksek boyutlu sayısal özellikler çıkararak kantitatif değerlendirme imkânı sunar. Bu çalışmada, göz muayenesi görüntülerinden elde edilen 746 radyomik özellik makine öğrenmesi yöntemleriyle işlenmiş; veri sızıntısını önlemek için hasta bazında veri bölme uygulanmış ve 20 tekrarlı değerlendirme ile güvenilir performans tahminleri elde edilmiştir.

2. Veri Seti

Parametre	Değer
Toplam hasta	69 (48 Normal, 21 Papilödem)
Sınıf oranı	%69.6 Normal / %30.4 Papilödem
Toplam ROI (satır)	966
Hasta başına ROI	14
Başlangıç özellik sayısı	746
Veri bölme oranı	%70 Eğitim / %10 Doğrulama / %20 Test
Tekrar sayısı	20 (farklı rastgele tohumlar)

Önemli not: Her iki CSV dosyasında PatientIndex değerlerinin 1-21 aralığında örtüşmesi nedeniyle hasta bazında veri bölmede sistematik bir hata tespit edilmiştir. Bu sorun, papilödem hastalarına 1000 birimlik ofset eklenerek giderilmiş (PatientIndex += 1000) ve tüm analizler düzeltilmiş veriler üzerinden yeniden yürütülmüştür.

3. Metodoloji

3.1 Veri Ön İşleme

Pipeline dört aşamadan oluşmaktadır: (1) Median imputation ile eksik değer doldurma — medyan kullanımı aykırı değerlere karşı dayanıklılık sağlar; (2) Düşük varyans filtresi (eşik: 0.01) ile neredeyse sabit özellikler elenir; (3) Yüksek korelasyon eleme (eşik: 0.95) ile bilgi tekrarı önlenir; (4) RobustScaler ile ölçekleme — medyan ve IQR tabanlı bu ölçekleyici aykırı değerlere dayanıklıdır. Tüm bu işlemler yalnızca eğitim verisine fit edilmiş; doğrulama ve test setlerine yalnızca transform uygulanmıştır. Sonuç olarak 746 özellik 147'ye indirilmiştir.

3.2 MRMR Özellik Seçimi

Minimum Redundancy Maximum Relevance (MRMR) yöntemi, hem sınıf ile yüksek mutual information taşıyan hem de seçilmiş özelliklerle düşük korelasyonlu özellikleri seçer. $k=\{5,8,10,15,20,25,30\}$ değerleri için doğrulama seti F1 skoru ölçülmüş ve $k=10$ optimal değer olarak belirlenmiştir. 147 özellik 10'a indirgenmiştir.

3.3 Hiperparametre Optimizasyonu (Optuna)

Optuna kütüphanesi Tree-structured Parzen Estimator (TPE) örnekleyici ile her model için 50 deneme üzerinden hiperparametre arama yapmıştır. İç çapraz doğrulama StratifiedGroupKFold (k=3) ile uygulanmış; hasta gruplama korunarak veri sızıntısı önlenmiştir. RF ve ET için n_estimators, max_depth, min_samples_split, max_features; GB için ek olarak learning_rate ve subsample optimize edilmiştir.

3.4 Ensemble ve Kalibrasyon

Soft Voting Ensemble, RF, ET ve GB modellerinin sınıf olasılıklarının ortalamasını alarak karar üretir. Sigmoid kalibrasyon (CalibratedClassifierCV, cv=3) modelin ham olasılık çıktılarını gerçek olasılıklara eşler ve Brier Score ile ECE-10 metrikleriyle değerlendirilir. Tüm süreç 20 farklı hasta bazında bölme üzerinden tekrarlanmıştır.

4. Sonular

4.1 Ensemble Model Performansı (20 Split Ortalaması)

Metrik	Sample Ort.	Sample Std	Patient Ort.	Patient Std
Accuracy	0.8937	±0.0640	0.9269	±0.0682
Precision	0.8892	±0.0874	1.0000	±0.0000
Recall	0.7455	±0.1971	0.7625	±0.2218
Macro F1	0.8629	±0.0928	0.8990	±0.1021
ROC-AUC	0.9226	±0.0839	0.9333	±0.1049
PR-AUC	0.8964	±0.1095	0.9262	±0.1165
Brier Score	0.0861	±0.0495	0.0725	±0.0476
ECE-10	0.1029	±0.0385	0.1531	±0.0399

Hasta bazında Precision=1.000 (Std=0.000): Model papilödem kararı verdiğinde hiç yanılmamıştır. Recall=0.763 ise gerçek papilödem hastalarının %24'ünün kaçırıldığını göstermektedir; bu oran 69 hastalık küçük veri seti için kabul edilebilir düzeydedir.

4.2 Bireysel Model Karşılaştırması

Model	Ortalama F1	Std	Sıralama
Random Forest (RF)	0.8705	0.0956	1
Extra Trees (ET)	0.8639	0.0922	2
Gradient Boosting (GB)	0.8563	0.0839	3
Ensemble (RF+ET+GB)	0.8629	0.0928	—

5. İstatistiksel Analiz

5.1 Friedman Testi

Ü model arasında genel performans farkını test etmek amacıyla parametrik olmayan Friedman testi uygulanmıştır (H0: tüm modeller eşit performansta). Test istatistiğı $\chi^2=7.772$, $p=0.021 < 0.05$ elde edilmiş; H0 reddedilmiştir. Modeller arasında istatistiksel olarak anlamlı fark mevcuttur.

5.2 Wilcoxon Signed-Rank Testi ve Bonferroni Düzeltmesi

Hangi model çifti arasında fark bulunduğunu belirlemek amacıyla ikili Wilcoxon Signed-Rank testleri uygulanmış; çoklu karşılaştırma sorunundan kaçınmak için Bonferroni düzeltmesi ile anlamlılık eşiğı $\alpha=0.05/3=0.0167$ 'ye çekilmiştir.

Karşılaştırma	Ort. Fark	p (raw)	p (Bonferroni)	Sonuç
RF vs ET	+0.0066 (RF)	0.334	1.000	Fark YOK
RF vs GB	+0.0142 (RF)	0.015	0.046	Fark VAR *
ET vs GB	+0.0076 (ET)	0.349	1.000	Fark YOK

* $p(\text{Bonferroni})=0.046 < 0.05$: RF, GB'ye göre istatistiksel olarak anlamlı biçimde üstündür. RF ile ET arasındaki fark istatistiksel anlam taşımamaktadır; her iki model eşdeğer performans sergilemektedir.

6. Tartışma

Bu çalışmada elde edilen hasta bazında ROC-AUC=0.933 ve Precision=1.000 değerleri, küçük örneklem büyüklüğü (n=69) göz önünde bulundurulduğunda güçlü sonuçlar olarak değerlendirilebilir. Precision'ın 1.000 olması, modelin papilödem yanlış alarması üretmediğini; bir başka deyişle, papilödem dediğinde her zaman doğru olduğunu göstermektedir. Tıbbi karar destek sistemlerinde bu özellik, gereksiz ileri tetkik ve hasta kaygısının önlenmesi açısından kritiktir.

Recall=0.763 değeri, gerçek papilödem hastalarının yaklaşık dörtte birinin kaçırıldığına işaret etmektedir. Bu sınırlamanın temel nedeni küçük veri seti ve sınıf dengesizliğidir (21 papilödem / 48 normal). Veri seti büyütüldüğünde ve/veya sınıf ağırlıklandırması uygulandığında recall değerinin iyileşmesi beklenmektedir.

MRMR özellik seçiminin 746 özelliği 10'a indirmesi hem overfitting riskini azaltmış hem de hesaplama maliyetini önemli ölçüde düşürmüştür. Feature importance analizinde Feature_0479'un açık ara en belirleyici özellik olduğu görülmüş; bu özelliğin klinik yorumu ilerideki çalışmalara konu olabilir.

7. Sonuç

Bu çalışmada radyomik özellikler kullanılarak papilödem tespiti için eksiksiz bir makine öğrenmesi pipeline'ı geliştirilmiştir. Hasta bazında veri bölme, MRMR özellik seçimi, Optuna optimizasyonu, Soft Voting Ensemble ve Sigmoid kalibrasyon adımlarından oluşan bu pipeline, hasta düzeyinde ROC-AUC=0.933 ve Macro F1=0.899 performansına ulaşmıştır. İstatistiksel analizler Random Forest'in Gradient Boosting'e göre anlamlı üstünlüğünü kanıtlamıştır. Elde edilen sonuçlar, radyomik tabanlı papilödem tespitinin klinik karar destek sistemleri için umut verici bir potansiyele sahip olduğuna işaret etmektedir.

Pipeline Bileşenleri: EDA → Ön İşleme → MRMR → Optuna → Ensemble → Kalibrasyon → İstatistiksel Analiz → Performans Grafikleri Uygulanan Testler: Friedman, Wilcoxon Signed-Rank, Bonferroni Değerlendirme: 20 tekrarlı hasta bazında çapraz doğrulama

8. Kaynaklar

- [1] Ding, C., & Peng, H. (2005). Minimum redundancy feature selection from microarray gene expression data. *Journal of Bioinformatics and Computational Biology*, 3(02), 185-205.
- [2] Akiba, T., Sano, S., Yanase, T., Ohta, T., & Koyama, M. (2019). Optuna: A next-generation hyperparameter optimization framework. *KDD '19*.
- [3] Breiman, L. (2001). Random forests. *Machine Learning*, 45(1), 5-32.
- [4] Geurts, P., Ernst, D., & Wehenkel, L. (2006). Extremely randomized trees. *Machine Learning*, 63(1), 3-42.
- [5] Friedman, J.H. (2001). Greedy function approximation: A gradient boosting machine. *Annals of Statistics*, 29(5), 1189-1232.
- [6] Wilcoxon, F. (1945). Individual comparisons by ranking methods. *Biometrics Bulletin*, 1(6), 80-83.

[7] Niculescu-Mizil, A., & Caruana, R. (2005). Predicting good probabilities with supervised learning. ICML '05.