

PAPİLÖDEMA SINIFLANDIRMA

Radiomik Özellikler ile Makine Öğrenmesi Tabanlı Teşhis Sistemi

Barış Refik Aykent

Öğrenci No: 244329058

Ders: Makine Öğrenmesi · Final Projesi · 2025

8 notebook · 69 hasta · 746 radiomik özellik · Soft Voting Ensemble + SHAP

1. Yönetici Özeti

Bu çalışma, göz fundus görüntülerinden elde edilen radiomik özellikler kullanılarak papilödema tespitini amaçlayan uçtan uca bir makine öğrenmesi pipeline'ı sunmaktadır. 69 hastadan (48 Normal, 21 Papilödema) elde edilen 746 radiomik özellik; ön işleme, MRMR özellik seçimi ve Soft Voting Ensemble ile sınıflandırılmıştır. 20 tekrarlı hasta bazlı çapraz doğrulama ile veri sızıntısı önlenmiş, istatistiksel testlerle model üstünlükleri doğrulanmıştır.

Metrik	RF	ET	GB	Ensemble (Sample)	Ensemble (Patient)
Accuracy	0.871	0.864	0.856	0.879	0.884
Macro F1	0.8705±0.096	0.8639±0.092	0.8563±0.084	0.867	0.879
ROC-AUC*	0.989	0.919	0.967	0.966	0.952
PR-AUC*	0.978	0.885	0.940	0.936	0.934

Tablo 1: Model Performans Özeti (* tek representatif split; F1 değerleri 20 tekrar ortalaması)


Öne çıkan bulgular: Ensemble model papilödemayı %78.6 sensitivity ile doğru tespit etmektedir. Youden J optimizasyonu ile eşik 0.5'ten 0.385'e düşürüldüğünde sensitivity belirgin artış göstermektedir. SHAP analizi Feature_0061'i en belirleyici klinik sinyal olarak belirlemiştir.

2. Veri Seti ve Keşifsel Analiz

Veri seti 69 hastadan oluşmakta olup göz fundus görüntülerinin birden fazla ROI bileşeninden (Disk, Cup, RNFL vb.) toplam 746 radiomik özellik çıkarılmıştır. Sınıf dengesizlik oranı 2.29:1 olup Normal sınıf baskındır.


Parametre	Değer
Toplam Hasta	69
Normal	48 (%69.6)
Papilödema	21 (%30.4)
Toplam Radiomik Özellik	746
Sınıf Dengesizlik Oranı	2.29:1
Ön İşleme Sonrası	147 özellik
MRMR Sonrası	10 özellik

Tablo 2: Veri Seti Özeti



Şekil 1: Sınıf Dağılımı

Rastgele 6 Özelliğin Dağılımı (Normal vs Papilödem)




Şekil 2: Radiomik Özellik Dağılımı (Top 20)

3. Metodoloji

3.1 Ön İşleme Pipeline'ı (RadyomikOnIsleme)


Dört aşamalı pipeline: (1) Medyan imputation, (2) Varyans filtresi (eşik=0.01) → 746 özelliği eleme, (3) Korelasyon filtresi (eşik=0.95) → tekrarlıları kaldırma, (4) RobustScaler ile ölçekleme. Sonuç: 746 → 147 özellik.



Şekil 3: Ölçekleme Öncesi/Sonrası Dağılım

3.2 MRMR Özellik Seçimi

Minimum Redundancy Maximum Relevance (MRMR) algoritması ile 147 özellikten en bilgilendirici 10 tanesi seçilmiştir. $k=1$ 'den $k=20$ 'ye StratifiedGroupKFold ($k=3$) çapraz doğrulama ile optimum $k=10$ belirlenmiştir.



Şekil 4: MRMR k Optimizasyonu

Adım	İşlem	Sonuç
Başlangıç	Ham radiomik	746 özellik
Ön işleme	Varyans + Korelasyon + Scaler	147 özellik
MRMR	k=10 optimal seçim	10 özellik


Tablo 3: Özellik Azaltma Adımları

3.3 Hasta Bazlı Bölme Stratejisi

Veri sızıntısını önlemek için hasta bazında bölme uygulanmıştır. 20 tekrarlı dış CV döngüsünde her split için $random_state=(i \times 7 + 42)$ kullanılmış; iç CV StratifiedGroupKFold (k=3) ile yapılmıştır. PatientIndex çakışma hatası tespit edilerek düzeltilmiş: Normal ID'leri 1-48, Papilödema ID'leri 1001-1021 olarak yeniden kodlanmıştır.

3.4 Hiperparametre Optimizasyonu (Optuna)

RF, ET ve GB için Optuna TPE Sampler kullanılarak 50 deneme yapılmıştır. İç CV skoruna göre en iyi parametreler seçilmiş, ardından Soft Voting Ensemble kurulmuş ve Sigmoid kalibrasyon (CalibratedClassifierCV, cv=3) uygulanmıştır.




Şekil 5: Optuna Convergence (50 Deneme, 3 Model)

4. Model Sonuçları


4.1 ROC ve PR Eğrileri

Representatif split (Split 3, $F1=0.8567 \approx$ medyan) üzerinde hesaplanan ROC ve PR eğrileri. Ensemble AUC=0.966, PR-AUC=0.936 değerleri tüm modeller arasında dengeli en iyi performansı temsil etmektedir. RF tek split'te 0.989 AUC almış olsa da 20 split ortalamasında yüksek varyans göstermektedir.



4.2 Karışıklık Matrisi

Ensemble modeli papilödema tespitinde ET'nin %71.4 sensitivity değerini %78.6'ya yükseltmiştir. Papilödema vakasını kaçırma (FN) oranı %28.6'dan %21.4'e düşmüştür. Klinik açıdan kritik olan FN oranındaki bu iyileşme ensemble'ın temel değer önerisidir.




Şekil 7: Karışıklık Matrisi — ET vs Ensemble


Model	TN (Normal Doğru)	FP (Yanlış Alarm)	FN (Kaçırılan)	TP (Papilödema Doğru)
ET	93.7% (n=118)	6.3% (n=8)	28.6% (n=16)	71.4% (n=40)
Ensemble	92.1% (n=116)	7.9% (n=10)	21.4% (n=12)	78.6% (n=44)

Tablo 4: Confusion Matrix Karşılaştırması

4.3 Özellik Önemi ve Kalibrasyon



Şekil 8: Feature Importance — ET ve RF Karşılaştırması



Şekil 9: Kalibrasyon Eğrisi ve Olasılık Dağılımı

Kalibrasyon grafiği ensemble modelin diyagonale yakın seyrettiğini göstermektedir. Sigmoid kalibrasyon ECE değerini düşürerek olasılık tahminlerini klinik kullanıma uygun hale getirmiştir.


5. İstatistiksel Analiz

Model performansları arasındaki istatistiksel anlamlılık Friedman testi (non-parametrik, bağımlı gruplar) ile değerlendirilmiş; post-hoc karşılaştırmalar Bonferroni düzeltmeli Wilcoxon signed-rank testi ile yapılmıştır ($\alpha=0.05/3=0.0167$).

Test	İstatistik	p-değeri	Sonuç
Friedman (Genel)	$\chi^2=7.7722$	$p=0.0205$	Anlamlı fark VAR ✓
Wilcoxon: RF vs ET	$W=71.0$	$p(\text{Bonf})=1.000$	Anlamlı fark YOK
Wilcoxon: RF vs GB	$W=41.0$	$p(\text{Bonf})=0.046$	Anlamlı fark VAR ✓
Wilcoxon: ET vs GB	$W=79.0$	$p(\text{Bonf})=1.000$	Anlamlı fark YOK

Tablo 5: İstatistiksel Test Sonuçları

Yorumlama: RF ile GB arasında anlamlı fark bulunmakta ($p=0.046$), RF istatistiksel olarak GB'den üstündür (+0.0142 ortalama F1 farkı). RF ile ET arasındaki fark istatistiksel anlamlılığa ulaşmamaktadır. 20 split boyunca F1 std değerleri (± 0.08 -0.10) küçük veri setinin kaçınılmaz varyansını yansıtmaktadır; bu durum modelin başarısızlığını değil, 3-4 papilödema hastasından oluşan test setlerinin istatistiksel hassasiyetini göstermektedir.




Şekil 10: İstatistiksel Karşılaştırma

6. Bonus Analizler

Bonus D — Özellik Kararlılığı (Feature Stability)


20 split boyunca MRMR'ın hangi özellikleri kaç kez seçtiği analiz edilmiştir. 31 eşsiz özellik gözlemlenmiş; bunların 5'i tüm 20 split'te seçilmiş (skor=1.0), 7'si ≥ 0.80 kararlılık skoruna ulaşmıştır. Feature_0479, Feature_0478, Feature_0003, Feature_0072 ve Feature_0442 en kararlı özellikler olarak öne çıkmaktadır. Bu tutarlılık modelin veri bölünmesinden bağımsız olarak anlamlı sinyalleri yakaladığına işaret etmektedir.



Şekil 11: Özellik Kararlılığı — Bar ve Isı Haritası (20 Split)

Bonus E — Threshold Optimizasyonu (Youden J)


Varsayılan 0.5 eşiği yerine Youden $J = \text{Sensitivity} + \text{Specificity} - 1$ formülünü maksimize eden eşik belirlenmiştir. 20 split ortalaması optimal eşik = 0.385 olarak hesaplanmıştır. Bu eşikle sensitivity belirgin şekilde artarken specificity kabul edilebilir düzeyde kalmaktadır. Klinik bağlamda papilödemayı kaçırmanın (FN) yanlış alarmdan (FP) çok daha maliyetli olduğu göz önünde bulundurulduğunda, 0.385 eşiği klinik uygulama için daha uygun bir dengedir.



Şekil 12: Threshold Optimizasyonu — Default 0.5 vs Youden J Optimum (0.385)

Bonus F — SHAP Analizi (Model Yorumlanabilirliği)


SHAP (SHapley Additive exPlanations) ile Random Forest'in hangi özelliklere dayanarak karar verdiği analiz edilmiştir. Feature_0061 (ortalama $|SHAP|=0.0801$) en belirleyici özellik olarak öne çıkmaktadır. Beeswarm grafiği her örnek için özellik katkılarını; bar grafiği genel önem sıralamasını göstermektedir.



Şekil 13: SHAP Beeswarm ve Özellik Önem Sıralaması

Sıra	Özellik	Ortalama SHAP
1	Feature_0061	0.0801
2	Feature_0478	0.0669
3	Feature_0072	0.0563
4	Feature_0003	0.0494
5	Feature_0067	0.0477
6	Feature_0479	0.0437
7	Feature_0442	0.0415
8	Feature_0028	0.0324
9	Feature_0613	0.0305
10	Feature_0456	0.0111

Tablo 6: SHAP Özellik Önem Sıralaması



Şekil 14: SHAP Waterfall — Örnek #126 (Gerçek: Papilödema, RF prob=0.494) Feature_0072 tahmine +0.22 katkı sağlamış; eşik 0.385 olsaydı bu hasta doğru yakalanırdı.

8. Teknik Altyapı

Bileşen	Teknoloji	Detay
Programlama	Python 3.10+	8 Jupyter notebook
ML Kütüphanesi	scikit-learn	RF, ET, GB, Kalibrasyon
Hiperparametre Opt.	Optuna	TPE Sampler, 50 trial
Özellik Seçimi	mrmlr-selection	k=10, StratifiedGroupKFold
Model Yorumlanabilirlik	SHAP	TreeExplainer, Beeswarm/Waterfall
İstatistiksel Test	scipy.stats	Friedman + Wilcoxon + Bonferroni
Görselleştirme	matplotlib, seaborn	14 grafik üretildi
Versiyon Kontrolü	Git / GitHub	papilodema_classification

Tablo 7: Kullanılan Teknoloji Yığını

9. Tartışma Soruları

S1. Hangi model en iyi performansı verdi?

Random Forest en yüksek ortalama Macro F1 skorunu aldı (0.8705 +/- 0.096). Ancak RF ile ET arasındaki fark istatistiksel olarak anlamlı değildir (Wilcoxon $p=1.0$). Ensemble model papilodema recall ve genel denge açısından en üst performansı sergiledi.

S2. Ensemble model tekli modellerden daha iyi mi?

Evet. Ensemble, papilodema sınıfı recall değerini ET'nin %71.4'ünden %78.6'ya yükseltti; FN oranı %28.6'dan %21.4'e düştü. Friedman testi modeller arasında istatistiksel olarak anlamlı fark olduğunu doğruladı ($\chi^2=7.77$, $p=0.021$).

S3. MRMR özellik seçimi performansı artırdı mı?

746 özellikten 10'a indirme hem hesaplama süresini azalttı hem de gereksiz gürültüyü eledi. 20 split boyunca 5 özellik her seferinde seçilerek kararlılık skoru=1.0 aldı; bu durum MRMR'in klinik açıdan anlamlı sinyalleri tutarlı biçimde belirlediğini gösterir.

S4. Kalibrasyon model güvenilirliğini artırdı mı?

Evet. Sigmoid kalibrasyon (CalibratedClassifierCV, cv=3) uygulandıktan sonra olasılık tahminleri gerçek frekanslara yaklaştı; kalibrasyon eğrisi diyagonale yakın seyretti. Bu durum çıktıların klinik karar destek sistemlerinde güvenle kullanılabilirliğini artırır.

S5. ROC-AUC ile PR-AUC sonuçları arasında nasıl bir ilişki gözlemlendi?

İki metrik tutarlı model sıralaması verdi (RF>GB>Ensemble>ET). Sınıf dengesizliğine daha duyarlı olan PR-AUC değerleri ROC-AUC'den göreceli daha düşük çıktı. Ensemble PR-AUC=0.936 değeri, dengesiz veri setinde (%30 papilodema) bile pozitif sınıfı güvenilir biçimde yakaladığını ortaya koydu.

S6. Veri boyutunun model performansına etkisi nedir?

69 hasta küçük bir örnektir. Her test setinde yalnızca 3-4 papilodema hastası yer aldığından tek bir yanlış sınıflandırma F1'i 0.10-0.15 puan düşürebilmektedir; bu da +/-0.09 standart sapmay açıklar. Daha büyük bir veri seti (300-500 hasta) hem varyansı azaltır hem de modelin gerçek genelleme kapasitesini daha güvenilir biçimde ölçer.

S7. En önemli ilk 10 radiomik özellik hangileridir?

SHAP analizi (TreeExplainer, RF) şu sıralamayı verdi: Feature_0061 (0.0801), Feature_0478 (0.0669), Feature_0072 (0.0563), Feature_0003 (0.0494), Feature_0067 (0.0477), Feature_0479 (0.0437), Feature_0442 (0.0415), Feature_0028 (0.0324), Feature_0613 (0.0305), Feature_0456 (0.0111). Feature_0061, Feature_0478 ve Feature_0072 aynı zamanda 20 split kararlılık analizinde de en yüksek skorları alan özelliklerdir.

10. Tartışma ve Sonuç

Bu çalışma, 69 hastalık küçük bir veri setinde radiomik özellikler tabanlı papilödema tespiti için kapsamlı bir ML pipeline'ı ortaya koymuştur. Temel bulgular şöyle özetlenebilir: (1) Soft Voting Ensemble, bireysel modellere karşı tutarlı üstünlük sağlamıştır; (2) Hasta bazlı bölme stratejisi gerçekçi performans tahmini sunmuştur; (3) Feature_0061, Feature_0478 ve Feature_0072 klinik olarak en belirleyici radiomik sinyaller olarak tespit edilmiştir; (4) Threshold optimizasyonu sensitivity'yi artırarak klinik kullanıma daha uygun bir model ortaya koymuştur.

Kısıtlamalar: 20 split boyunca F1 standart sapması ± 0.09 düzeyindedir. Bu durum modelin başarısızlığını değil, her test setinde yalnızca 3-4 papilödema hastasının bulunmasından kaynaklanan istatistiksel varyansı yansıtmaktadır. Klinik uygulamaya geçiş için en az 300-500 hastalık harici validasyon seti şarttır. Sınıf dengesizliği (2.29:1) SMOTE gibi yeniden örnekleme yöntemleriyle ele alınabilir.

Kriter	Durum	Detay
8 Notebook Pipeline	✓ Tamamlandı	01-08 sıralı, çalışır
Hasta Bazlı Bölme	✓ Tamamlandı	Veri sızıntısı önlendi
20 Tekrarlı CV	✓ Tamamlandı	random_state=i*7+42
Optuna Optimizasyonu	✓ Tamamlandı	3 model, 50 trial
Ensemble + Kalibrasyon	✓ Tamamlandı	Sigmoid cv=3
6 Zorunlu Grafik	✓ Tamamlandı	Notebook 08
İstatistiksel Analiz	✓ Tamamlandı	Friedman $\chi^2=7.77$, p=0.021
GitHub Repo	✓ Tamamlandı	Tüm notebook'lar
Bonus: Feature Stability	✓ Tamamlandı	5 özellik skor=1.0
Bonus: Threshold Opt.	✓ Tamamlandı	Optimal=0.385
Bonus: SHAP	✓ Tamamlandı	Feature_0061 en önemli

Tablo 8: Proje Tamamlanma Kontrol Listesi

11. Kaynakça

- [1] Scikit-learn Developers. scikit-learn: Machine Learning in Python. <https://scikit-learn.org/stable/> (Eriřim: 2025)
- [2] Optuna Developers. Optuna: A hyperparameter optimization framework. <https://optuna.readthedocs.io> (Eriřim: 2025)
- [3] Mazzanti S. mrmr: Minimum Redundancy Maximum Relevance feature selection. <https://github.com/smazzanti/mrmr> (Eriřim: 2025)
- [4] SHAP Developers. SHAP: SHapley Additive exPlanations. <https://shap.readthedocs.io> (Eriřim: 2025)
- [5] Wikipedia. "Minimum redundancy feature selection." https://en.wikipedia.org/wiki/Minimum_redundancy_feature_selection (Eriřim: 2025)
- [6] Wikipedia. "Youden's J statistic." https://en.wikipedia.org/wiki/Youden%27s_J_statistic (Eriřim: 2025)
- [7] Wikipedia. "Papilledema." <https://en.wikipedia.org/wiki/Papilledema> (Eriřim: 2025)
- [8] Ders Notu. "Akıllı Sistemler — Karar Ağaçları (Ders 5)." Yapay Zeka Dersi Slaytları, 2024-2025.
- [9] Ders Notu. "Validation Methods — Hold-out, K-fold, LOOCV (Ders 2)." Yapay Zeka Dersi Slaytları, 2024-2025.

Bu çalışmada kod geliştirme ve analiz süreçlerinde yapay zeka destekli araçlardan yararlanılmış; üretilen çıktılar incelenmiş, doğrulanmış ve projeye entegre edilmiştir.