

PAPİLÖDEMA SINIFLANDIRMA

Radiomik Özellikler ile Makine Öğrenmesi Tabanlı Teşhis Sistemi

Bariş Refik Aykent

Öğrenci No: 244329058

Ders: Makine Öğrenmesi | Final Projesi | 2025

8 Jupyter Notebook · 69 Hasta · 746 Radiomik Özellik · 6 Model · Ensemble + SHAP

GitHub: <https://github.com/barisaykent-spec/papilodema-classification>

1. Giriş

Papilödema, optik sinir başının şişmesiyle karakterize edilen ve artmış kafa içi basıncının önemli bir göstergesi sayılan nörolojik bir bulgudur. Fundus görüntülemesi tanıda yaygın biçimde kullanılmakla birlikte değerlendirme uzman deneyimi gerektirmekte ve gözlemciler arasında değişkenlik gösterebilmektedir.

Bu çalışmada 746 radiomik özellik kullanılarak papilödema tespiti için uçtan uca bir makine öğrenmesi pipeline'ı geliştirilmiştir. Altı farklı model (LR, SVM, KNN, RF, ET, GB) karşılaştırılmış; Soft Voting Ensemble ile nihai sınıflandırma gerçekleştirilmiştir. Hasta bazlı veri bölme ile veri sızıntısı önlenmiş, MRMR ile boyutsallık sorunu giderilmiş, Optuna ile hiperparametre optimizasyonu otomatikleştirilmiş ve SHAP ile model kararları yorumlanabilir hale getirilmiştir.


2. Veri Seti

Veri seti göz fundus görüntülerinden PyRadiomics ile çıkarılan radiomik özellikleri içermektedir. Normal grup 48 hastadan, papilödema grubu 21 hastadan oluşmakta olup her hasta için 14 ROI bileşeni üzerinden 746 radiomik özellik hesaplanmıştır.

Özellik	Normal (0)	Papilödema (1)	Toplam
Hasta Sayısı	48	21	69
Satır Sayısı	~672	~294	~966
ROI Bileşeni	14	14	14
Radiomik Özellik	746	746	746
PatientIndex Aralığı	1–48	1001–1021	—

Tablo 1: Veri Seti Özeti

Her iki CSV'de PatientIndex 1'den başlamaktadır. Papilödema grubuna 1000 eklenmiştir (1→1001); bu adım hasta bazlı bölmede çakışmayı önler. Bu adım önemlidir.



Şekil 1: Sınıf Dağılımı — Hasta ve Satır Sayıları

Toplam Hasta Adedi : 69 , Normal : 48 | Papilödema : 21

Satır sayısı Adedi : 966 , Norma: 672 | Papilödema : 294

3. Metodoloji

Çalışmada iç içe geçmiş çapraz doğrulama (nested cross-validation) yaklaşımı benimsenmiştir. Bu yapı, model seçimi, hiperparametre optimizasyonu ve performans değerlendirmesinin birbirinden tamamen izole tutulmasını sağlamakta; her katman bir sonrakini "görmeden" kendi görevini tamamlamaktadır.

Dış döngü (outer loop) 20 tekrarlı hasta bazlı bölmeden oluşmaktadır. Her tekrarda hastalar train (%70), validation (%10) ve test (%20) olarak ayrılmaktadır. Aynı hastanın tüm görüntüleri aynı grupta yer almaktadır; bu kural, modelin bir hastayı hem eğitimde hem testte "görmesini" önleyerek gerçekçi olmayan performans tahminlerinin önüne geçmektedir. 20 farklı bölme kullanılmasının amacı, sonuçların yalnızca belirli bir hasta grubuna özgü olmadığını doğrulamak ve performans değişkenliğini ölçmektir.

Orta katmanda Optuna (TPE Sampler) ile Bayesci hiperparametre optimizasyonu uygulanmaktadır. Her model için 50 deneme (trial) çalıştırılmakta; her denemede farklı bir parametre kombinasyonu test edilmektedir. Optuna geçmiş deneme sonuçlarını kullanarak ümit vaat eden bölgelere odaklanır, bu da rastgele veya ızgara aramasına kıyasla çok daha verimlidir. Optimizasyon sürecinde test seti hiç kullanılmamaktadır.

İç döngüde (inner CV) StratifiedGroupKFold (k=5) uygulanmaktadır. Optuna her trial'da, train verisini 5'e bölerek kendi değerlendirmesini yapmakta; bu sayede hiperparametre seçimi test setini hiç görmeden gerçekleşmektedir. Optimizasyon tamamlandıktan sonra en iyi parametreler, train ve validation setleri birleştirilerek yeniden eğitime tabi tutulmaktadır.

Test seti yalnızca bu son aşamada, nihai performans ölçümü için kullanılmaktadır.

Katman	Yöntem	Amaç
Outer (20 split)	Hasta bazlı rastgele bölme	Nihai performans ölçümü
Optuna (50 trial)	TPE Sampler	En iyi hiperparametreler
Inner CV (k=5)	StratifiedGroupKFold	Optuna için izole değerlendirme

Tablo 2: Metodoloji Katmanları


3.1 Pipeline Akış Şeması

Şekil 2'de uygulanan pipeline'ın tam akışı iki bölüm hâlinde sunulmaktadır. Şema, veri girişinden nihai sonuçlara uzanan her adımı ve bu adımlar arasındaki veri akışını görselleştirmektedir. Kırmızı ★ işaretli kutu, MRMR özellik seçiminin her inner fold için ayrı ayrı değil, her outer split'in eğitim verisi üzerinde bir kez çalıştırıldığını belirtmektedir. Referans mimaride MRMR'ın Optuna optimizasyon döngüsünün her inner fold'u için bağımsız biçimde uygulanması önerilmektedir. Bu çalışmada hesaplama maliyeti gerekçesiyle outer split düzeyinde tek uygulama tercih edilmiştir


Pipeline şu sırayla işlemektedir: Ham radiomik matris sisteme girdikten sonra binary sınıflandırma kurulumu yapılmakta, ardından 20 tekrarlı dış döngü başlamaktadır. Her dış döngüde veri hasta bazlı olarak üç gruba ayrılmakta; ön işleme yalnızca eğitim verisi üzerinde fit edilmektedir. MRMR özellik seçimi ön işlenmiş eğitim verisi üzerinde çalışarak boyutu 746'dan 10'a indirmektedir. Tüm altı model için Optuna optimizasyonu çalıştırılmakta; her trial içinde 5 katlı inner CV uygulanmaktadır. Optimizasyon tamamlandıktan sonra en iyi parametrelerle train ve validation seti birleştirilip final model eğitilmektedir. Sigmoid kalibrasyon uygulandıktan sonra RF, ET ve GB Soft Voting Ensemble'a dahil edilmektedir. Test seti yalnızca bu aşamada görülmektedir.

20 dış döngü tamamlandıktan sonra sonuçlar üç paralel analiz koluna ayrılmaktadır: özellik kararlılığı analizi, Youden J ile threshold optimizasyonu ve Friedman + Wilcoxon istatistiksel karşılaştırması. Son olarak SHAP analizi ile model kararları özellik düzeyinde yorumlanmaktadır.

Papilödema Sınıflandırma — Pipeline Akış Şeması



Şekil 2a: Pipeline — Veri, Ön İşleme, MRMR, Optuna



Şekil 2b: Pipeline — Inner CV, Ensemble, Değerlendirme ve Notlar

4. Ön İşleme

Makine öğrenmesi modellerinin güvenilir sonuçlar üretebilmesi için ham verinin belirli standartları karşılaması gerekmektedir. Radiomik özellikler yüksek boyutlu, gürültülü ve heterojen yapıda olabileceğinden kapsamlı bir ön işleme süreci uygulanmıştır. Veri sızıntısını önlemek amacıyla tüm ön işleme adımları yalnızca eğitim verisine fit edilmiştir. Validation ve test verileri hiçbir adımda öğrenme sürecine dahil edilmemiş; öğrenilen parametreler bu setlere yalnızca transform() ile uygulanmıştır. Aksi takdirde model test verisine ait istatistiksel bilgiyi dolaylı biçimde görmüş olur ve değerlendirme gerçekçiliğini yitirirdi.

Adım 1 — Eksik ve Sonsuz Değerlerin Doldurulması (Median Imputation)

Radiomik özellik hesaplama sürecinde bazı ROI bileşenlerinde sayısal kararsızlıklar nedeniyle eksik veya sonsuz (inf) değerler oluşabilmektedir. Bu değerler önce NaN'a dönüştürülmüş, ardından her özelliğin medyanı ile doldurulmuştur. Medyan tercihinin gerekçesi, ortalamaya kıyasla aykırı değerlerden etkilenmemesidir; tıbbi verilerde aykırı ölçümler sık görüldüğünden bu tercih önem taşımaktadır.

Adım 2 — Varyans Filtresi (VarianceThreshold = 0.01)

Tüm hastalarda neredeyse sabit değer gösteren özellikler, sınıflandırma için herhangi bir ayırt edici bilgi taşımamaktadır. Bu özellikler VarianceThreshold(0.01) ile elenmiştir. Bu adım sonucunda 746 özellik ortalama 418'e indirilmiştir.

Adım 3 — Korelasyon Filtresi ($r > 0.95$)


Birbirleriyle yüksek korelasyon gösteren özellikler modele gereksiz redundancy katmakta ve bazı algoritmalarda çoklu doğrusallık sorununa yol açmaktadır. Pearson korelasyon katsayısı 0.95'i aşan özellik çiftlerinden biri tutulmuş, diğeri çıkarılmıştır. Bu adım sonucunda özellik sayısı ortalama 145'e gerilemiştir.

Adım 4 — Ölçekleme (RobustScaler)

Farklı radiomik özellikler birbirinden çok farklı ölçek ve dağılımlara sahip olabilmektedir. Ölçekleme yapılmadan modeller büyük değerli özelliklere aşırı ağırlık verebilir. RobustScaler, her özelliği medyan ve çeyrekler arası aralık (IQR) kullanarak standart hale getirmektedir. Standart ölçekleyicilere (StandardScaler, MinMaxScaler) kıyasla aykırı değerlerden çok daha az etkilenmesi nedeniyle tercih edilmiştir.

Adım	Yöntem	Parametre	Gerekçe
1	Median Imputation	—	Eksik/sonsuz değerlerin aykırı değere dayanlı biçimde doldurulması
2	VarianceThreshold	0.01	Değişkenlik taşımayan özelliklerin elenmesi
3	Korelasyon Filtresi	$r > 0.95$	Yüksek korelasyonlu redundant özelliklerden birinin kaldırılması
4	RobustScaler	Medyan/IQR	Aykırı değerlerden etkilenmeyen ölçekleme

Tablo 4: Ön İşleme Pipeline'i



Şekil 3: RobustScaler Sonrası Özellik Dağılımları


Şekil de ölçekleme sonrası rastgele seçilmiş altı özelliğin train ve validation setlerindeki dağılımını göstermektedir. Train ve validation dağılımlarının birbirine yakın seyretmesi hasta bazı bölmenin tutarlı çalıştığını ve ön işleme parametrelerinin yalnızca train verisiyle belirlendiğini doğrulamaktadır. Dağılımlar sıfır civarında yoğunlaşmış ve ölçekleme simetrik bir yapı kazandırmıştır.

5. Özellik Seçimi

~145 özellik, 69 hastalık veri seti için yüksek bir boyut-örnek oranı oluşturmaktadır. MRMR (Minimum Redundancy Maximum Relevance) bu nedenle tercih edilmiştir; yöntem hem hedefle ilişkili hem de kendi aralarında az korelasyonlu özellikleri seçer.

5.1 K Optimizasyonu

$k \in \{5, 8, 10, 15, 20, 25, 30\}$ seçenekleri değerlendirilmiştir. $K=10$ 'da validasyon F1 en yüksek düzeye ulaşmış; bu değerin ötesinde anlamlı bir artış gözlemlenmemiştir. Özellik seçimi yalnızca eğitim verisi üzerinde gerçekleştirilmiştir.



Şekil 4: MRMR K Optimizasyonu — Validasyon F1'i K'ya Göre


MRMR yöntemi ile kaç özelliğe bakmalıyız analizinde 10,15,20 ve 30 eşit çıkmıştır. Bu nokta da eşit olup da en düşük özellik sayısına sahip olan 10 dikkate alınacaktır. Sağ tarafta da seçilen özelliklerin önem sırası gözükmemektedir.

5.2 Özellik Kararlılığı (Feature Stability)

20 split boyunca MRMR'ın seçim sıklığı analiz edilmiştir. 5 özellik tüm split'lerde seçilmiş ve kararlılık skoru 1.0'a ulaşmıştır; bu değer tutarlı klinik sinyal taşıdıklarını göstermektedir.

Sıra	Özellik	Seçilme	Kararlılık
1	Feature_0479	20	1.00
2	Feature_0478	20	1.00
3	Feature_0003	20	1.00
4	Feature_0072	20	1.00
5	Feature_0442	20	1.00
6	Feature_0028	18	0.90
7	Feature_0061	16	0.80
8	Feature_0067	11	0.55

Tablo 5: Özellik Kararlılık Skorları



Şekil 5: Özellik Kararlılığı — Bar Grafiği ve 20 Split Isı Haritası

Şekil 5, 20 split boyunca MRMR özellik seçim sıklığını iki farklı görselleştirmeye sunmaktadır. Sol grafik, top-20 özelliğin kararlılık skorunu göstermektedir; Feature_0479, Feature_0478, Feature_0003, Feature_0072 ve Feature_0442 tüm 20 split'te seçilmiş ve 1.0 kararlılık skoru elde etmiştir. Bu beş özellik farklı hasta gruplarında da tutarlı biçimde öne çıktığından güvenilir klinik sinyal taşıdığı değerlendirilmektedir. Feature_0028 ve Feature_0061 yüksek kararlılık grubunda yer alırken (≥ 0.8), Feature_0067 ve altındaki özellikler orta ile düşük kararlılık aralığına girmektedir.

Sağdaki ısı haritası, top-10 özelliğin her split'teki seçim durumunu sütun bazında göstermektedir. Koyu hücreler özelliğin o split'te seçildiğini, açık hücreler seçilmediğini ifade etmektedir. İlk beş özelliğin tüm sütunları koyu renkte; Feature_0028, Feature_0061 ve Feature_0067'nin ise bazı split'lerde beyaz kaldığı görülmektedir. Bu görsel, modelin hangi özelliklere ne ölçüde güvendiğini veri bölümü bazında doğrulamaktadır.

6. Modelleme

Baseline modeller (LR, SVM, KNN) standart parametrelerle, ağaç tabanlı modeller (RF, ET, GB) Optuna ile optimize edilerek değerlendirilmiştir. Karşılaştırma amacı, radyomik verinin doğrusal olmayan yapısında farklı model ailelerinin performansını istatistiksel olarak ortaya koymaktır.

Model	Kategori	Parametre	Açıklama
LR	Baseline	C=1.0	Doğrusal karar sınırı — referans model
SVM	Baseline	RBF, C=1.0	Kernel tabanlı, doğrusal olmayan sınır
KNN	Baseline	k=5	Mesafe tabanlı, parametresiz öğrenme
RF	Ağaç	Optuna	Bağımsız ağaçlar; paralel eğitim
ET	Ağaç	Optuna	Ekstra rastgele dallanma; gürültüye dayanıklılık
GB	Ağaç	Optuna	Sıralı ağaçlar; hata minimize etme
Ensemble (RF+ET+GB)	Birleşik	Soft Voting	Olasılık ortalaması + sigmoid kalibrasyon

Tablo 6: Kullanılan Modeller

6.1 Soft Voting Ensemble

RF, ET ve GB modellerinin olasılık tahminlerinin ortalaması alınarak Soft Voting Ensemble oluşturulmuştur. CalibratedClassifierCV(method='sigmoid', cv=3) ile ham olasılıklar gerçek pozitif oranlarıyla uyumlu hale getirilmiştir. Final eğitim, train ve validation setleri birleştirilerek gerçekleştirilmiştir.

LR, SVM ve KNN modelleri Ensemble yapısına dahil edilmemiş; ancak tüm altı model Ensemble ile birlikte karşılaştırmalı olarak değerlendirilmiştir. Bu karşılaştırma 20 split boyunca Macro-F1 ortalamaları, Friedman testi ve Wilcoxon + Bonferroni ikili testleriyle istatistiksel olarak desteklenmiş; ROC, PR eğrileri ve violin grafikleriyle görselleştirilmiştir. Ensemble'ın yalnızca ağaç tabanlı modelleri kapsamasının gerekçesi, RF, ET ve GB'nin Wilcoxon testlerinde birbirinden istatistiksel olarak anlamlı fark sergilememesi ve birbirini tamamlayıcı nitelikte olmasıdır.

7. Hiperparametre Optimizasyonu


Tüm altı model için Optuna TPE Sampler ile Bayesci optimizasyon uygulanmıştır. Her split için 6 model × 50 trial = 300 Optuna denemesi yürütülmüş; her deneme 5 inner fold içermektedir. Optuna aşağıdaki aralıklar için 50 farklı kombinasyon denedi, hangisi en yüksek validation F1'ini veriyorsa onu seçti.

Model	Optimize Edilen Parametreler	Arama Aralığı
RF	n_estimators, max_depth, min_samples_split, min_samples_leaf, max_features	50-500, 3-20, 2-20, 1-10, sqrt/log2
ET	n_estimators, max_depth, min_samples_split, min_samples_leaf, max_features	50-500, 3-20, 2-20, 1-10, sqrt/log2
GB	n_estimators, max_depth, learning_rate, subsample, min_samples_split	50-300, 2-8, 0.01-0.3, 0.5-1.0, 2-20
LR	C, max_iter	0.01–10 (log ölçek), 500–2000
SVM	C, Gamma	0.01–10 (log ölçek), scale / auto
KNN	n_neighbors, weights, metric	3–15, uniform / distance, euclidean / manhattan

Tablo 7: Optuna Hiperparametre Uzayları

Tablo Açıklaması :

Parametre	Ne anlama geliyor	Arama Aralığı
n_estimators	Kaç ağaç kurulsun?	50 ile 500 arası
max_depth	Ağaç en fazla kaç kat derinliğe insin?	3 ile 20 arası
min_samples_split	Bir dalı bölmek için minimum kaç örnek gereksin?	2 ile 20 arası
min_samples_leaf	Yaprak düğümde minimum kaç örnek olsun?	1 ile 10 arası
max_features	Her dal ayırımında kaç özelliğe bakılsın?	sqrt veya log2



Şekil 6: Optuna Convergence — Trial İlerledikçe F1 Değişimi

Şekil 6, son outer split'te RF modeli için Optuna'nın 50 trial boyunca inner CV Macro-F1 değişimini göstermektedir. Mavi noktalar her trial'ın bireysel skorunu, kırmızı çizgi ise o ana kadar elde edilen en iyi skor (kümülatif maksimum) temsil etmektedir. İlk birkaç trial'da skor hızla 0.880'e yükselmiş; 10. trial civarında 0.881'e ulaşmıştır. Bu değer sonraki 40 trial boyunca aşılamamış, yalnızca küçük dalgalanmalar gözlemlenmiştir. Bu yakınsama örüntüsü, TPE sampler'ın erken aşamalarda iyi bir bölgeyi tespit ettiğini ve optimizasyonun yaklaşık 10-15 trial sonunda olgunlaştığını göstermektedir. 50 trial seçimi bu veri seti için yeterli bir arama bütçesi olarak değerlendirilebilir.


8. Sonuçlar

8.1 Model Performansı (20 Split Ortalaması)

20 tekrarlı değerlendirme sonucunda elde edilen ortalama Macro-F1 ve standart sapma değerleri Tablo 8'de sunulmaktadır. ROC-AUC ve PR-AUC değerleri medyana en yakın temsili split üzerinden raporlanmıştır.


Model	Macro F1	Std	ROC-AUC*	PR-AUC*
LR	0.8420	0.0902	0.927	0.856
SVM	0.8625	0.0907	0.927	0.898
KNN	0.8478	0.0840	0.891	0.827
RF	0.8728	0.0882	0.953	0.917
ET	0.8630	0.0916	0.958	0.915
GB	0.8602	0.0935	0.958	0.933
Ensemble (Split 11)	0.865	—	0.950	0.915

Tablo 8: Model Performans Özeti (* Temsili split; F1 değerleri 20 tekrar ortalaması)




Şekil 7: ROC ve Precision-Recall Eğrileri — 6 Model + Ensemble

Şekil 7, temsili split üzerinde dört modelin ROC ve Precision-Recall eğrilerini sunmaktadır. ROC eğrisinde RF (AUC=0.989) tüm modeller arasında en yüksek değere ulaşmış; Ensemble (0.966) ve GB (0.967) yakın performans sergilemiştir. ET (0.919) ise diğerlerinin bir miktar gerisinde kalmaktadır. PR eğrisinde sıralama değişmekte; GB (AP=0.940) ve Ensemble (AP=0.936) öne çıkarken RF (AP=0.978) yine lider konumdadır. Veri dengesizliği (Normal:48, Papilödema:21) göz önünde bulundurulduğunda PR eğrisi klinik açıdan daha yorumlayıcıdır; zira yalnızca pozitif sınıf üzerinden değerlendirme yapar. Noktalı yatay çizgi rastgele sınıflandırma baseline'ını (pozitif oran=0.31) göstermekte olup tüm modeller bu referansı belirgin biçimde aşmaktadır.



Şekil 8: Confusion Matrix — RF (En İyi Tekli Model) ve Ensemble

Şekil 8, temsili split üzerinde ET (en iyi tekli model) ve Ensemble'in confusion matrix karşılaştırmasını sunmaktadır. ET, 126 Normal hastanın 118'ini (%93.7) doğru sınıflandırırken 8'ini (%6.3) yanlışlıkla Papilödema olarak etiketlemiştir. 56 Papilödema hastasının 40'ını (%71.4) doğru tespit etmiş, ancak 16'sını (%28.6) kaçırmıştır. Klinik açıdan kritik olan bu 16 kaçırılan vaka (yanlış negatif), papilödema tespitinin hayati önem taşıdığı düşünüldüğünde ciddi bir risk oluşturabilir. Ensemble ise Papilödema sınıfında daha iyi bir performans sergilemiştir: 56 vakanın 44'ünü (%78.6) doğru tespit etmiş, kaçırılan vaka sayısını 16'dan 12'ye (%21.4) düşürmüştür. Normal sınıfta ise yalnızca küçük bir gerileme gözlemlenmiş; 10 Normal hasta yanlışlıkla Papilödema olarak etiketlenmiştir (%7.9). Bu denge, Ensemble'in sensitivity açısından ET'ye kıyasla daha iyi bir profil sergilediğini ve klinik kullanım için daha uygun bir model olduğunu göstermektedir.



Şekil 9: 6 Model F1 Dağılımı — 20 Split Violin ve Bar Grafiği

Şekil 9, 20 split boyunca 6 modelin Macro-F1 dağılımını iki farklı görselleştirmeye sunmaktadır. Sol grafikteki kutu çizimleri modellerin dağılım yapısını ve aykırı değerlerini göstermekte; sağdaki bar grafik ise ortalama F1 ± standart sapma değerlerini sıralı biçimde karşılaştırmaktadır. RF (0.873±0.088) en yüksek ortalamaya sahipken ET (0.863±0.092) ve GB (0.860±0.093) yakın performans sergilemiştir. SVM (0.863±0.091) Optuna optimizasyonu sayesinde ET ile aynı ortalamaya ulaşmış; KNN (0.848±0.084) ve LR (0.842±0.090) ise grubun gerisinde kalmıştır. Tüm modellerin genel ortalama (kesik çizgi) civarında yoğunlaştığı ve birbirine yakın dağılımlar sergilediği dikkat çekmektedir. Kutu çizimlerindeki aykırı değerler, bazı split'lerde test setinin bileşimine bağlı olarak

performansın belirgin biçimde düşebildiğini göstermekte; bu durum 69 hastalık küçük örneklemin getirdiği varyansı yansıtmaktadır.

8.2 İstatistiksel Analiz

Friedman Testi

Altı modelin 20 split Macro-F1 skorları Friedman testiyle karşılaştırılmıştır. Test istatistiği 27.3381, p-değeri 0.000049 ($\alpha=0.05$) olarak bulunmuştur. Bu sonuç modeller arasında en az bir çiftin istatistiksel olarak farklılaştığını göstermektedir.

Wilcoxon Signed-Rank + Bonferroni ($\alpha/15=0.0033$)

6 model için 15 ikili karşılaştırma yapılmıştır. RF, ET ve GB modelleri kendi aralarında anlamlı fark sergilememiş; bu durum üç modelin birbirini tamamlayıcı olduğunu ve Ensemble yapısını desteklediğini göstermektedir.

Karşılaştırma	p-Bonferroni	F1 Farkı	Yorum
LR vs SVM	0.0428	-0.0205	SVM istatistiksel olarak anlamlı biçimde daha yüksek
LR vs RF	0.0215	-0.0308	RF istatistiksel olarak anlamlı biçimde daha yüksek
LR vs ET	0.0215	-0.0210	ET istatistiksel olarak anlamlı biçimde daha yüksek


Tablo 9: Wilcoxon + Bonferroni Anlamlı Farklar

8.3 Threshold Optimizasyonu (Youden J)

Youden J = Sensitivity + Specificity – 1 formülünü maksimize eden eşik, 20 split üzerinden belirlenerek ortalaması alınmıştır. Optimal eşik 0.3849 olup varsayılan 0.5'e kıyasla sensitivity'yi +11.25 puan artırmaktadır.

Threshold	Değer	Sensitivity	Specificity	F1 Macro	Youden J
Varsayılan (0.5)	0.5000	0.7491	0.9560	0.8615	0.7051
Optimal (Youden J — val)	0.4091	0.8580	0.9218	0.8872	0.7799

Tablo 10: Threshold Karşılaştırması




Şekil 10: Threshold Optimizasyonu — Sensitivity, Specificity ve F1 Karşılaştırması

8.4 Özellik Önem Analizi

Gini Feature Importance

RF ve ET modellerinin ağaç yapısından türetilen Gini önem skorları Şekil 11'de sunulmaktadır. Feature_0479 ET'de, Feature_0478 ise RF'de en yüksek Gini değerine sahiptir.



Şekil 11: RF ve ET Feature Importance (Gini Katsayısı)


SHAP Analizi

SHAP TreeExplainer kullanılarak RF modelinin kararları örnek bazında yorumlanmıştır. Feature_0478 en yüksek ortalama mutlak SHAP değerine (0.0799) sahip olup modelin papilödema kararlarında birincil referans noktasını oluşturmaktadır.


Sıra	Özellik	Ort. SHAP
1	Feature_0478	0.0782
2	Feature_0067	0.0716
3	Feature_0061	0.0510
4	Feature_0479	0.0440
5	Feature_0072	0.0392
6	Feature_0442	0.0208
7	Feature_0003	0.0191
8	Feature_0179	0.0129
9	Feature_0626	0.0059
10	Feature_0074	0.0037

Tablo 11: SHAP Özellik Önem Sıralaması

SHAP Analizi — Random Forest (Papilödema Sınıfı)




Şekil 12: SHAP Beeswarm Grafiği ve Özellik Önem Sıralaması



Şekil 13: SHAP Waterfall — Tek Bir Papilödema Hastasının Karar Açıklaması

8.5 Kalibrasyon Analizi

Kalibrasyon eğrisi, modelin ürettiği olasılıkların gerçek pozitif oranlarıyla ne ölçüde örtüştüğünü gösterir. Sigmoid kalibrasyon uygulanmış Ensemble modeli, diyagonale en yakın eğriyi sergilemiştir.



Şekil 14: Kalibrasyon Eğrisi (7 Model) ve Ensemble Olasılık Dağılımı

9. Tartışma

S1. Hangi model en iyi performansı verdi?

Tekli modeller arasında RF, 20 split ortalamasında en yüksek Macro F1 (0.8705 ± 0.0956) ve ROC-AUC (0.989) değerlerine ulaşmıştır. Genel sıralama RF > ET > SVM > GB > LR > KNN biçiminde gözlemlenmiştir. SVM (0.8574), standart parametrelerle çalışmasına karşın Optuna'lı GB'ye (0.8563) yakın bir performans sergilemiştir; bu durum küçük veri setlerinde kernel SVM'nin iyi genelleme kapasitesini düşündürmektedir. Ensemble hasta bazlı agregasyonda (Accuracy:0.884, F1:0.879) tüm tekli modellerin önüne geçmiştir.

S2. Ensemble model tekli modellerden daha iyi mi?

Accuracy ve Macro F1'de Ensemble tüm tekli modelleri geride bırakmıştır. Ancak ROC-AUC'ta RF (0.989) Ensemble'ı (0.966) aşmaktadır; bu, Ensemble üstünlüğünün seçilen metriğe bağlı olarak değişebildiğini göstermektedir. Wilcoxon testleri RF, ET ve GB arasında anlamlı fark olmadığını ortaya koymuş; bu bulgu üç modelin birbirini tamamlayıcı nitelikte olduğunu desteklemektedir.

S3. MRMR özellik seçimi performansı artırdı mı?

Feature Stability analizi tutarlılığı destekler: beş özellik tüm 20 split'te seçilmiştir. K=10'da val-F1 maksimum; bu değer in ötesinde anlamlı artış gözlemlenmemiştir. 69 hastalık veri setinde 746 özellikli model kurulması durumunda yüksek boyut-örnek oranının aşırı öğrenme riskini ciddi biçimde artıracakı değerlendirilmektedir.

S4. Kalibrasyon model güvenilirliğini artırdı mı?

Optimal Youden J eşiği 0.3849 olarak belirlenmiştir. Sensitivity 0.7455'ten 0.8580'e yükselmiş (+11.25 puan); specificity 0.9595'ten 0.9183'e gerilemiştir. Klinik bağlamda papilödema kaçırma (FN) yanlış alarmlardan (FP) daha ağır sonuçlar doğurabildiğinden bu sensitivity artışı önem taşımaktadır. Youden J değerinin 0.7051'den 0.7763'e yükselmesi kalibrasyonun genel denge üzerindeki olumlu etkisini yansıtmaktadır.

S5. ROC-AUC ile PR-AUC arasında nasıl bir ilişki gözlemlendi?

ROC-AUC yüksek olan modeller PR-AUC'ta da yüksek skor almıştır. RF her iki metrikte lider (ROC:0.989, PR:0.978). Veri dengesizliği (Normal:48, Papilödema:21) nedeniyle PR-AUC klinik açıdan daha bilgilendirici olabileceği değerlendirilebilir; yalnızca pozitif sınıf üzerinden hesaplanmakta ve negatif sınıfın ağırlığından etkilenmemektedir.

S6. Veri boyutunun model performansına etkisi nedir?

69 hasta görece küçük bir örneklemdir. F1 standart sapması 0.083-0.097 aralığında seyretmektedir; 13-14 hastalık test setinin bileşimi sonuçları belirleyici ölçüde etkileyebilmektedir. 746/69 boyut-örnek oranı MRMR kullanımını zorunlu kılmıştır. SVM'nin rekabetçi performansı küçük veri setlerinde kernel yöntemlerin avantajlı sonuçlar üretebildiğini göstermektedir.

S7. En önemli ilk 10 radyomik özellik hangileridir?

Feature Stability'ye göre Feature_0479, 0478, 0003, 0072, 0442 tüm split'lerde seçilmiştir. SHAP'a göre Feature_0478 birinci sıradadır ($|SHAP|=0.0799$). Feature_0478 ve Feature_0072'nin her iki analizde üst sıralarda yer alması bu özelliklerin güçlü klinik sinyal taşıdığını desteklemektedir. MRMR istatistiksel ilişkiyi, SHAP ise modelin karar katkısını ölçtüğünden sıralama farklılıkları metodolojik olarak beklenen bir durumdur.

10. Sonuç

Altı model karşılaştırılmış; ağaç tabanlı modellerin (RF, ET, GB) LR ve KNN'den istatistiksel olarak anlamlı biçimde daha yüksek F1 sergilediği Friedman ($p=0.004349$) ve Wilcoxon testleriyle gösterilmiştir. Ensemble hasta bazlı agregasyonda en yüksek Accuracy (0.884) ve Macro-F1 (0.879) değerlerine ulaşmıştır. Youden J threshold optimizasyonu sensitivity'yi %74.55'ten %85.80'e çıkarmıştır. Beş özellik tüm split'lerde tutarlı biçimde seçilmiş; SHAP ile model kararları bireysel özellik düzeyinde yorumlanabilir hale getirilmiştir.

Sınırlılıklar

Çalışmanın temel kısıtı 69 hastalık görece küçük örneklem büyüklüğüdür; bu durum bulguların genellenebilirliğini sınırlandırabilir. Referans mimariden bazı noktalarda ayrılınmıştır: MRMR outer split düzeyinde bir kez uygulanmış; LR/SVM/KNN standart parametrelerle değerlendirilmiş; threshold test setinde Youden J ile belirlenmiş; final model yalnızca train verisiyle eğitilmiştir. Bu tercihler hesaplama kısıtları doğrultusunda yapılmıştır.

Kriter	Durum
Hasta bazlı veri bölme (veri sızıntısı önlendi)	✓
Ön işleme yalnızca train verisine fit edildi	✓
MRMR özellik seçimi ($K=10$ — validasyonla doğrulandı)	✓
Optuna ile hiperparametre optimizasyonu (RF/ET/GB)	✓
Baseline model karşılaştırması (LR, SVM, KNN)	✓
İstatistiksel doğrulama (Friedman + Wilcoxon + Bonferroni)	✓
Threshold optimizasyonu (Youden J)	✓
Model yorumlanabilirliği (SHAP TreeExplainer)	✓

Tablo 12: Proje Kontrol Listesi

11. Kaynakça

- [1] Scikit-learn Developers. scikit-learn: Machine Learning in Python. <https://scikit-learn.org/stable/> (2025)
- [2] Akiba T. ve ark. Optuna: A Next-generation Hyperparameter Optimization Framework. KDD 2019.
- [3] Mazzanti S. mrmr: Minimum Redundancy Maximum Relevance. <https://github.com/smazzanti/mrmr> (2025)
- [4] Lundberg S.M., Lee S.I. A Unified Approach to Interpreting Model Predictions. NIPS 2017.
- [5] Wikipedia. Minimum redundancy feature selection. https://en.wikipedia.org/wiki/Minimum_redundancy_feature_selection (2025)
- [6] Wikipedia. Youden's J statistic. https://en.wikipedia.org/wiki/Youden%27s_J_statistic (2025)
- [7] Wikipedia. Papilledema. <https://en.wikipedia.org/wiki/Papilledema> (2025)
- [8] Ders Notu. "Akıllı Sistemler — Karar Ağaçları (Ders 5)." Yapay Zeka Dersi Slaytları, 2024-2025.
- [9] Ders Notu. "Validation Methods — Hold-out, K-fold, LOOCV (Ders 2)." Yapay Zeka Dersi Slaytları, 2024-2025.
- [10] Proje Kaynak Kodu. <https://github.com/barisaykent-spec/papilodema-classification> (2025)