

PAPİLÖDEMA SINIFLANDIRMA

Radiomik Özellikler ile Makine Öğrenmesi Tabanlı Teşhis Sistemi

Bariş Refik Aykent

Öğrenci No: 244329058

Ders: Makine Öğrenmesi | Final Projesi | 2025

8 Jupyter Notebook · 69 Hasta · 746 Radiomik Özellik · 6 Model · Ensemble + SHAP

GitHub: <https://github.com/barisaykent-spec/papilodema-classification>

1. Giriş

Papilödema, optik sinir başının şişmesiyle karakterize edilen ve artmış kafa içi basıncının önemli bir göstergesi sayılan nörolojik bir bulgudur. Fundus görüntülemesi tanıda yaygın biçimde kullanılmakla birlikte değerlendirme uzman deneyimi gerektirmekte ve gözlemciler arasında değişkenlik gösterebilmektedir.

Bu çalışmada 746 radiomik özellik kullanılarak papilödema tespiti için uçtan uca bir makine öğrenmesi pipeline'ı geliştirilmiştir. Altı farklı model (LR, SVM, KNN, RF, ET, GB) karşılaştırılmış; Soft Voting Ensemble ile nihai sınıflandırma gerçekleştirilmiştir. Hasta bazlı veri bölme ile veri sızıntısı önlenmiş, MRMR ile boyutsallık sorunu giderilmiş, Optuna ile hiperparametre optimizasyonu otomatikleştirilmiş ve SHAP ile model kararları yorumlanabilir hale getirilmiştir.


2. Veri Seti

Veri seti göz fundus görüntülerinden PyRadiomics ile çıkarılan radiomik özellikleri içermektedir. Normal grup 48 hastadan, papilödema grubu 21 hastadan oluşmakta olup her hasta için 14 ROI bileşeni üzerinden 746 radiomik özellik hesaplanmıştır.

Özellik	Normal (0)	Papilödema (1)	Toplam
Hasta Sayısı	48	21	69
Satır Sayısı	~672	~294	~966
ROI Bileşeni	14	14	14
Radiomik Özellik	746	746	746
PatientIndex Aralığı	1–48	1001–1021	—

Tablo 1: Veri Seti Özeti

Her iki CSV'de PatientIndex 1'den başlamaktadır. Papilödema grubuna 1000 eklenmiştir (1→1001); bu adım hasta bazlı bölmede çakışmayı önler.



Şekil 1: Sınıf Dağılımı — Hasta ve Satır Sayıları

Toplam Hasta Adedi : 69 , Normal : 48 | Papilödema : 21

Satır sayısı Adedi : 966 , Norma: 672 | Papilödema : 294

3. Metodoloji

Çalışmada iç içe geçmiş çapraz doğrulama (nested CV) yaklaşımı benimsenmiştir. Her katman veri sızıntısını önleyecek biçimde bağımsız olarak tasarlanmıştır.

Katman	Yöntem	Amaç
Outer (20 split)	Hasta bazlı rastgele bölme	Nihai performans ölçümü
Optuna (50 trial)	TPE Sampler	En iyi hiperparametreler
Inner CV (k=5)	StratifiedGroupKFold	Optuna için izole değerlendirme


Tablo 2: Metodoloji Katmanları

3.1 Hasta Bazlı Veri Bölme


Aynı hastanın tüm görüntüleri ya tamamen eğitim ya da tamamen test setinde yer almıştır. Bölme oranları Train:%70, Validation:%10, Test:%20 olarak belirlenmiş; 20 farklı rastgele bölme ile sonuçların tek bir bölmeye özgü olmadığı doğrulanmıştır.

3.2 Pipeline Akış Şeması

Şekil 2'de uygulanan pipeline akışı sunulmaktadır. Kırmızı ★ kutular referans mimariden sapmaları göstermektedir.



Şekil 2a: Pipeline — Veri, Ön İşleme, MRMR, Optuna



Şekil 2b: Pipeline — Inner CV, Ensemble, Değerlendirme ve Notlar


4. Ön İşleme

Tüm adımlar yalnızca eğitim verisine fit edilmiş; test verisi yalnızca transform() ile dönüştürülmüştür. Bu yaklaşım veri sızıntısını önlemektedir.

Adım	Yöntem	Parametre	Gerekçe
1	Median Imputation	—	Eksik/sonsuz değerlerin aykırı değere dayanıklı biçimde doldurulması
2	VarianceThreshold	0.01	Değişkenlik taşımayan özelliklerin elenmesi
3	Korelasyon Filtresi	$r > 0.95$	Yüksek korelasyonlu redundant özelliklerden birinin kaldırılması
4	RobustScaler	Medyan/IQR	Aykırı değerlerden etkilenmeyen ölçekleme

Tablo 4: Ön İşleme Pipeline'i

746 özellik varyans filtresiyle ~418'e, korelasyon elemeyle ~145 özelliğe indirilmiştir. Bu %80'i aşan boyut azaltımı MRMR öncesi gürültüyü önemli ölçüde azaltmaktadır.




Şekil 3: RobustScaler Sonrası Özellik Dağılımları

5. Özellik Seçimi

~145 özellik, 69 hastalık veri seti için yüksek bir boyut-örnek oranı oluşturmaktadır. MRMR (Minimum Redundancy Maximum Relevance) bu nedenle tercih edilmiştir; yöntem hem hedefle ilişkili hem de kendi aralarında az korelasyonlu özellikleri seçer.

5.1 K Optimizasyonu

$k \in \{5, 8, 10, 15, 20, 25, 30\}$ seçenekleri değerlendirilmiştir. $K=10$ 'da validasyon F1 en yüksek düzeye ulaşmış; bu değer in ötesinde anlamlı bir artış gözlemlenmemiştir. Özellik seçimi yalnızca eğitim verisi üzerinde gerçekleştirilmiştir.



Şekil 4: MRMR K Optimizasyonu — Validasyon F1'i K'ya Göre


MRMR yöntemi ile kaç özelliğe bakmalıyız analizinde 10,15,20 ve 30 eşit çıkmıştır. Bu nokta da eşit olup da en düşük özellik sayısına sahip olan 10 dikkate alınacaktır. Sağ tarafta da seçilen özelliklerin önem sırası gözükmemektedir.

5.2 Özellik Kararlılığı (Feature Stability)

20 split boyunca MRMR'ın seçim sıklığı analiz edilmiştir. 5 özellik tüm split'lerde seçilmiş ve kararlılık skoru 1.0'a ulaşmıştır; bu değer tutarlı klinik sinyal taşıdıklarını göstermektedir.

Sıra	Özellik	Seçilme	Kararlılık
1	Feature_0479	20	1.00
2	Feature_0478	20	1.00
3	Feature_0003	20	1.00
4	Feature_0072	20	1.00
5	Feature_0442	20	1.00
6	Feature_0028	18	0.90
7	Feature_0061	16	0.80
8	Feature_0067	11	0.55

Tablo 5: Özellik Kararlılık Skorları



Şekil 5: Özellik Kararlılığı — Bar Grafiği ve 20 Split Isı Haritası

Top 20 ye giren özelliklerden kararlılığı 1 çıkan 5 özellik en üstte gözlemlenmiştir.

6. Modelleme

Baseline modeller (LR, SVM, KNN) standart parametrelerle, ağaç tabanlı modeller (RF, ET, GB) Optuna ile optimize edilerek değerlendirilmiştir. Karşılaştırma amacı, radyomik verinin doğrusal olmayan yapısında farklı model ailelerinin performansını istatistiksel olarak ortaya koymaktır.

Model	Kategori	Parametre	Açıklama
LR	Baseline	C=1.0	Doğrusal karar sınırı — referans model
SVM	Baseline	RBF, C=1.0	Kernel tabanlı, doğrusal olmayan sınır
KNN	Baseline	k=5	Mesafe tabanlı, parametresiz öğrenme
RF	Ağaç	Optuna	Bağımsız ağaçlar; paralel eğitim
ET	Ağaç	Optuna	Ekstra rastgele dallanma; gürültüye dayanıklılık
GB	Ağaç	Optuna	Sıralı ağaçlar; hata minimize etme
Ensemble (RF+ET+GB)	Birleşik	Soft Voting	Olasılık ortalaması + sigmoid kalibrasyon

Tablo 6: Kullanılan Modeller

6.1 Soft Voting Ensemble


RF, ET ve GB modellerinin olasılık tahminlerinin ortalaması alınarak Ensemble oluşturulmuştur. CalibratedClassifierCV(method='sigmoid', cv=3) ile ham olasılıklar gerçek frekanslarla uyumlu hale getirilmiştir.

7. Hiperparametre Optimizasyonu

RF, ET ve GB için Optuna TPE Sampler ile Bayesci optimizasyon uygulanmıştır. TPE, geçmiş trial sonuçlarını kullanarak ümit vaat eden parametre bölgelerini önceliklendirir; bu yaklaşım ızgara aramasına kıyasla hesaplama verimliliği açısından belirgin bir avantaj sağlar. Her split için 3 model × 50 trial = 150 Optuna denemesi yürütülmüştür. LR, SVM ve KNN standart parametrelerle baseline olarak değerlendirilmiştir.

Model	Optimize Edilen Parametreler	Arama Aralığı
RF	n_estimators, max_depth, min_samples_split, min_samples_leaf, max_features	50-500, 3-20, 2-20, 1-10, sqrt/log2
ET	n_estimators, max_depth, min_samples_split, min_samples_leaf, max_features	50-500, 3-20, 2-20, 1-10, sqrt/log2
GB	n_estimators, max_depth, learning_rate, subsample, min_samples_split	50-300, 2-8, 0.01-0.3, 0.5-1.0, 2-20
LR/SVM/KNN	— (standart parametreler)	—

Tablo 7: Optuna Hiperparametre Uzayları



Şekil 6: Optuna Convergence — Trial İlerledikçe F1 Değişimi


8. Sonuçlar

8.1 Model Performansı (20 Split Ortalaması)


20 tekrarlı değerlendirme sonucunda elde edilen ortalama Macro-F1 ve standart sapma değerleri Tablo 8'de sunulmaktadır. ROC-AUC ve PR-AUC değerleri medyana en yakın temsili split üzerinden raporlanmıştır.

Model	Macro F1	Std	ROC-AUC*	PR-AUC*
LR	0.8420	0.0902	0.927	0.856
SVM	0.8625	0.0907	0.927	0.898
KNN	0.8478	0.0840	0.891	0.827
RF	0.8728	0.0882	0.953	0.917
ET	0.8630	0.0916	0.958	0.915
GB	0.8602	0.0935	0.958	0.933
Ensemble (Split 11)	0.865	—	0.950	0.915


Tablo 8: Model Performans Özeti (* Temsili split; F1 değerleri 20 tekrar ortalaması)



Şekil 7: ROC ve Precision-Recall Eğrileri — 6 Model + Ensemble



Şekil 8: Confusion Matrix — RF (En İyi Tekli Model) ve Ensemble



Şekil 9: 6 Model F1 Dağılımı — 20 Split Violin ve Bar Grafiği

8.2 İstatistiksel Analiz

Friedman Testi

Altı modelin 20 split Macro-F1 skorları Friedman testiyle karşılaştırılmıştır. Test istatistiği 27.3381, p-değeri 0.000049 ($\alpha=0.05$) olarak bulunmuştur. Bu sonuç modeller arasında en az bir çiftin istatistiksel olarak farklılaştığını göstermektedir.

Wilcoxon Signed-Rank + Bonferroni ($\alpha/15=0.0033$)

6 model için 15 ikili karşılaştırma yapılmıştır. RF, ET ve GB modelleri kendi aralarında anlamlı fark sergilememiş; bu durum üç modelin birbirini tamamlayıcı olduğunu ve Ensemble yapısını desteklediğini göstermektedir.

Karşılaştırma	p-Bonferroni	F1 Farkı	Yorum
LR vs SVM	0.0428	-0.0205	SVM istatistiksel olarak anlamlı biçimde daha yüksek
LR vs RF	0.0215	-0.0308	RF istatistiksel olarak anlamlı biçimde daha yüksek
LR vs ET	0.0215	-0.0210	ET istatistiksel olarak anlamlı biçimde daha yüksek


Tablo 9: Wilcoxon + Bonferroni Anlamlı Farklar

8.3 Threshold Optimizasyonu (Youden J)

Youden J = Sensitivity + Specificity – 1 formülünü maksimize eden eşik, 20 split üzerinden belirlenerek ortalaması alınmıştır. Optimal eşik 0.3849 olup varsayılan 0.5'e kıyasla sensitivity'yi +11.25 puan artırmaktadır.

Threshold	Değer	Sensitivity	Specificity	F1 Macro	Youden J
Varsayılan (0.5)	0.5000	0.7491	0.9560	0.8615	0.7051
Optimal (Youden J — val)	0.4091	0.8580	0.9218	0.8872	0.7799

Tablo 10: Threshold Karşılaştırması




Şekil 10: Threshold Optimizasyonu — Sensitivity, Specificity ve F1 Karşılaştırması

8.4 Özellik Önem Analizi

Gini Feature Importance

RF ve ET modellerinin ağaç yapısından türetilen Gini önem skorları Şekil 11'de sunulmaktadır. Feature_0479 ET'de, Feature_0478 ise RF'de en yüksek Gini değerine sahiptir.



Şekil 11: RF ve ET Feature Importance (Gini Katsayısı)


SHAP Analizi

SHAP TreeExplainer kullanılarak RF modelinin kararları örnek bazında yorumlanmıştır. Feature_0478 en yüksek ortalama mutlak SHAP değerine (0.0799) sahip olup modelin papilödema kararlarında birincil referans noktasını oluşturmaktadır.


Sıra	Özellik	Ort. SHAP
1	Feature_0478	0.0782
2	Feature_0067	0.0716
3	Feature_0061	0.0510
4	Feature_0479	0.0440
5	Feature_0072	0.0392
6	Feature_0442	0.0208
7	Feature_0003	0.0191
8	Feature_0179	0.0129
9	Feature_0626	0.0059
10	Feature_0074	0.0037

Tablo 11: SHAP Özellik Önem Sıralaması

SHAP Analizi — Random Forest (Papilödema Sınıfı)




Şekil 12: SHAP Beeswarm Grafiği ve Özellik Önem Sıralaması



Şekil 13: SHAP Waterfall — Tek Bir Papilödema Hastasının Karar Açıklaması

8.5 Kalibrasyon Analizi

Kalibrasyon eğrisi, modelin ürettiği olasılıkların gerçek pozitif oranlarıyla ne ölçüde örtüştüğünü gösterir. Sigmoid kalibrasyon uygulanmış Ensemble modeli, diyagonale en yakın eğriyi sergilemiştir.



Şekil 14: Kalibrasyon Eğrisi (7 Model) ve Ensemble Olasılık Dağılımı

9. Tartışma

S1. Hangi model en iyi performansı verdi?

Tekli modeller arasında RF, 20 split ortalamasında en yüksek Macro F1 (0.8705 ± 0.0956) ve ROC-AUC (0.989) değerlerine ulaşmıştır. Genel sıralama RF > ET > SVM > GB > LR > KNN biçiminde gözlemlenmiştir. SVM (0.8574), standart parametrelerle çalışmasına karşın Optuna'lı GB'ye (0.8563) yakın bir performans sergilemiştir; bu durum küçük veri setlerinde kernel SVM'nin iyi genelleme kapasitesini düşündürmektedir. Ensemble hasta bazlı agregasyonda (Accuracy:0.884, F1:0.879) tüm tekli modellerin önüne geçmiştir.

S2. Ensemble model tekli modellerden daha iyi mi?

Accuracy ve Macro F1'de Ensemble tüm tekli modelleri geride bırakmıştır. Ancak ROC-AUC'ta RF (0.989) Ensemble'ı (0.966) aşmaktadır; bu, Ensemble üstünlüğünün seçilen metriğe bağlı olarak değişebildiğini göstermektedir. Wilcoxon testleri RF, ET ve GB arasında anlamlı fark olmadığını ortaya koymuş; bu bulgu üç modelin birbirini tamamlayıcı nitelikte olduğunu desteklemektedir.

S3. MRMR özellik seçimi performansı artırdı mı?

Feature Stability analizi tutarlılığı destekler: beş özellik tüm 20 split'te seçilmiştir. K=10'da val-F1 maksimum; bu değer in ötesinde anlamlı artış gözlemlenmemiştir. 69 hastalık veri setinde 746 özellikli model kurulması durumunda yüksek boyut-örnek oranının aşırı öğrenme riskini ciddi biçimde artıracakı değerlendirilmektedir.

S4. Kalibrasyon model güvenilirliğini artırdı mı?

Optimal Youden J eşiği 0.3849 olarak belirlenmiştir. Sensitivity 0.7455'ten 0.8580'e yükselmiş (+11.25 puan); specificity 0.9595'ten 0.9183'e gerilemiştir. Klinik bağlamda papilödema kaçırma (FN) yanlış alarmdan (FP) daha ağır sonuçlar doğurabildiğinden bu sensitivity artışı önem taşımaktadır. Youden J değerinin 0.7051'den 0.7763'e yükselmesi kalibrasyonun genel denge üzerindeki olumlu etkisini yansıtmaktadır.

S5. ROC-AUC ile PR-AUC arasında nasıl bir ilişki gözlemlendi?

ROC-AUC yüksek olan modeller PR-AUC'ta da yüksek skor almıştır. RF her iki metrikte lider (ROC:0.989, PR:0.978). Veri dengesizliği (Normal:48, Papilödema:21) nedeniyle PR-AUC klinik açıdan daha bilgilendirici olabileceği değerlendirilebilir; yalnızca pozitif sınıf üzerinden hesaplanmakta ve negatif sınıfın ağırlığından etkilenmemektedir.

S6. Veri boyutunun model performansına etkisi nedir?

69 hasta görece küçük bir örneklemdir. F1 standart sapması 0.083-0.097 aralığında seyretmektedir; 13-14 hastalık test setinin bileşimi sonuçları belirleyici ölçüde etkileyebilmektedir. 746/69 boyut-örnek oranı MRMR kullanımını zorunlu kılmıştır. SVM'nin rekabetçi performansı küçük veri setlerinde kernel yöntemlerin avantajlı sonuçlar üretebildiğini göstermektedir.

S7. En önemli ilk 10 radyomik özellik hangileridir?

Feature Stability'ye göre Feature_0479, 0478, 0003, 0072, 0442 tüm split'lerde seçilmiştir. SHAP'a göre Feature_0478 birinci sıradadır ($|SHAP|=0.0799$). Feature_0478 ve Feature_0072'nin her iki analizde üst sıralarda yer alması bu özelliklerin güçlü klinik sinyal taşıdığını desteklemektedir. MRMR istatistiksel ilişkiyi, SHAP ise modelin karar katkısını ölçtüğünden sıralama farklılıkları metodolojik olarak beklenen bir durumdur.

10. Sonuç

Altı model karşılaştırılmış; ağaç tabanlı modellerin (RF, ET, GB) LR ve KNN'den istatistiksel olarak anlamlı biçimde daha yüksek F1 sergilediği Friedman ($p=0.004349$) ve Wilcoxon testleriyle gösterilmiştir. Ensemble hasta bazlı agregasyonda en yüksek Accuracy (0.884) ve Macro-F1 (0.879) değerlerine ulaşmıştır. Youden J threshold optimizasyonu sensitivity'yi %74.55'ten %85.80'e çıkarmıştır. Beş özellik tüm split'lerde tutarlı biçimde seçilmiş; SHAP ile model kararları bireysel özellik düzeyinde yorumlanabilir hale getirilmiştir.

Sınırlılıklar

Çalışmanın temel kısıtı 69 hastalık görece küçük örneklem büyüklüğüdür; bu durum bulguların genellenebilirliğini sınırlandırabilir. Referans mimariden bazı noktalarda ayrılınmıştır: MRMR outer split düzeyinde bir kez uygulanmış; LR/SVM/KNN standart parametrelerle değerlendirilmiş; threshold test setinde Youden J ile belirlenmiş; final model yalnızca train verisiyle eğitilmiştir. Bu tercihler hesaplama kısıtları doğrultusunda yapılmıştır.

Kriter	Durum
Hasta bazlı veri bölme (veri sızıntısı önlendi)	✓
Ön işleme yalnızca train verisine fit edildi	✓
MRMR özellik seçimi ($K=10$ — validasyonla doğrulandı)	✓
Optuna ile hiperparametre optimizasyonu (RF/ET/GB)	✓
Baseline model karşılaştırması (LR, SVM, KNN)	✓
İstatistiksel doğrulama (Friedman + Wilcoxon + Bonferroni)	✓
Threshold optimizasyonu (Youden J)	✓
Model yorumlanabilirliği (SHAP TreeExplainer)	✓

Tablo 12: Proje Kontrol Listesi

11. Kaynakça

- [1] Scikit-learn Developers. scikit-learn: Machine Learning in Python. <https://scikit-learn.org/stable/> (2025)
- [2] Akiba T. ve ark. Optuna: A Next-generation Hyperparameter Optimization Framework. KDD 2019.
- [3] Mazzanti S. mrmr: Minimum Redundancy Maximum Relevance. <https://github.com/smazzanti/mrmr> (2025)
- [4] Lundberg S.M., Lee S.I. A Unified Approach to Interpreting Model Predictions. NIPS 2017.
- [5] Wikipedia. Minimum redundancy feature selection. https://en.wikipedia.org/wiki/Minimum_redundancy_feature_selection (2025)
- [6] Wikipedia. Youden's J statistic. https://en.wikipedia.org/wiki/Youden%27s_J_statistic (2025)
- [7] Wikipedia. Papilledema. <https://en.wikipedia.org/wiki/Papilledema> (2025)
- [8] Ders Notu. "Akıllı Sistemler — Karar Ağaçları (Ders 5)." Yapay Zeka Dersi Slaytları, 2024-2025.
- [9] Ders Notu. "Validation Methods — Hold-out, K-fold, LOOCV (Ders 2)." Yapay Zeka Dersi Slaytları, 2024-2025.
- [10] Proje Kaynak Kodu. <https://github.com/barisaykent-spec/papilodema-classification> (2025)