

# PAPİLÖDEMA SINIFLANDIRMA

*Radiomik Özellikler ile Makine Öğrenmesi Tabanlı Teşhis Sistemi*

---

**Barış Refik Aykent**

Öğrenci No: 244329058

Ders: Makine Öğrenmesi · Final Projesi · 2025

---

8 Jupyter Notebook · 69 Hasta · 746 Radiomik Özellik · 6 Model · Soft Voting Ensemble + SHAP

GitHub: <https://github.com/barisaykent-spec/papilodema-classification>

## 1. Giriş

Papilödema, optik sinir başının şişmesiyle karakterize edilen ve artmış kafa içi basıncının önemli bir göstergesi sayılan nörolojik bir bulgudur. Fundus görüntülemesi, tanıda yaygın olarak kullanılmakla birlikte, görüntü değerlendirmesi uzman deneyimi gerektirmekte ve gözlemciler arasında değişkenlik gösterebilmektedir. Radyomik yaklaşım, tıbbi görüntülerden yüksek boyutlu sayısal özellikler çıkararak nesnel ve tekrarlanabilir sınıflandırma imkânı sunmaktadır. Bu çalışmada, göz fundus görüntülerinden elde edilen 746 radiomik özellik kullanılarak papilödema tespiti için uçtan uca bir makine öğrenmesi pipeline'ı geliştirilmiştir. Altı farklı model (Lojistik Regresyon, Destek Vektör Makinesi, K-En Yakın Komşu, Rastgele Orman, Ekstra Ağaçlar ve Gradyan Artırma) karşılaştırılmış; Soft Voting Ensemble ile nihai sınıflandırma gerçekleştirilmiştir. Çalışmada hasta bazlı veri bölme ile veri sızıntısının önlenmesi, MRMR ile boyutsallık sorununun giderilmesi, Optuna ile otomatik hiperparametre optimizasyonu ve SHAP analizi ile model yorumlanabilirliğinin desteklenmesi temel metodolojik tercihler olarak belirlenmiştir.


## 2. Veri Seti

Çalışmada kullanılan veri seti, iki gruptan oluşan fundus görüntüsü kaynaklı radiomik ölçümlerden meydana gelmektedir. Normal grup 48 hastadan, papilödema grubu ise 21 hastadan oluşmakta olup her hasta için 14 ROI (Region of Interest) bileşeni üzerinden 746 radiomik özellik çıkarılmıştır.

| Özellik                 | Normal (0) | Papilödema (1) | Toplam |
|-------------------------|------------|----------------|--------|
| Hasta Sayısı            | 48         | 21             | 69     |
| Satır Sayısı (Yaklaşık) | 672        | 294            | 966    |
| ROI Bileşeni            | 14         | 14             | 14     |
| Radiomik Özellik        | 746        | 746            | 746    |
| PatientIndex Aralığı    | 1 - 48     | 1001 - 1021    | —      |

Tablo 1: Veri Seti Özeti

Her iki CSV dosyasında PatientIndex sütunu 1'den başlamaktadır. Veri birleştirme öncesinde olası çakışmayı gidermek amacıyla papilödema grubunun hasta indekslerine 1000 eklenmiştir (örn. 1→1001). Bu adım, hasta bazlı bölmede aynı bireyin farklı alt kümelere düşmemesini sağlamak açısından önem taşımaktadır.



Şekil 1: Sınıf ve Satır Dağılımı

### 3. Metodoloji

Çalışmada iç içe geçmiş çapraz doğrulama (nested cross-validation) yaklaşımı benimsenmiştir. Bu yapı üç katmandan oluşmaktadır: dış döngü (outer), Optuna optimizasyonu ve iç çapraz doğrulama (inner CV). Her katman birbirinden bağımsız olarak veri sızıntısını önleyecek biçimde tasarlanmıştır.

| Katman            | Yöntem                                              | Amaç                                |
|-------------------|-----------------------------------------------------|-------------------------------------|
| Outer (20 split)  | Hasta bazlı rastgele bölme<br>random_state = i×7+42 | Güvenilir performans ölçümü         |
| Optuna (50 trial) | TPE Sampler — Bayesci arama                         | En iyi hiperparametreleri belirleme |
| Inner CV (k=3)    | StratifiedGroupKFold                                | Optuna için izole değerlendirme     |

Tablo 2: Metodoloji Katmanları

#### 3.1 Hasta Bazlı Veri Bölme

Aynı hastaya ait tüm görüntülerin ya tamamen eğitim ya da tamamen test setinde yer alması sağlanmıştır. Görüntü bazlı bölmede model, aynı bireyin bazı görüntülerini eğitimde görmüş olacağından, test performansı gerçekçi olmayan biçimde yüksek çıkabilir. Bölme oranı Train:%70, Validation:%10, Test:%20 olarak belirlenmiş; 20 farklı rastgele bölme ile sonuçların belirli bir bölüme özgü olmadığı doğrulanmıştır.

#### 3.2 Pipeline Akış Şeması ve Referans Mimariden Sapmalar

Aşağıdaki tablo, uygulanan pipeline'ın referans mimariden farklılaştığı noktaları özetlemektedir. Bu tercihler metodolojik bir hata olmayıp, hesaplama kısıtları ve kapsam değerlendirmeleri doğrultusunda yapılmıştır.

| Bileşen        | Referans Mimari                   | Bu Çalışmada Uygulanan                       |
|----------------|-----------------------------------|----------------------------------------------|
| MRMR yeri      | Her inner fold'da ayrı            | Outer split'te train verisi üzerinde bir kez |
| Optuna kapsamı | Tüm modeller (LR, SVM, KNN dahil) | Yalnızca RF, ET, GB                          |

| Bileşen        | Referans Mimari             | Bu Çalışmada Uygulanan                |
|----------------|-----------------------------|---------------------------------------|
| Inner CV fold  | k=5                         | k=3                                   |
| Threshold opt. | Validation setinde          | Test setinde Youden J istatistiği ile |
| Final eğitim   | Train + Validation birleşik | Yalnızca train verisi                 |

Tablo 3: Referans Mimariden Sapmalar


## 4. Ön İşleme

Tüm ön işleme adımları yalnızca eğitim verisine fit edilmiş; test verisi hiçbir adımda öğrenme sürecine dahil edilmemiş, yalnızca transform() ile dönüştürülmüştür. Bu yaklaşım, testin gerçek dünya koşullarını temsil etmesini sağlamaktadır. Ön işleme, RadyomikOnIsleme sınıfı aracılığıyla dört adımda uygulanmıştır:

| Adım | Yöntem              | Parametre    | Gerekçe                                                                           |
|------|---------------------|--------------|-----------------------------------------------------------------------------------|
| 1    | Median Imputation   | —            | Eksik ve sonsuz değerlerin ortalamaya kıyasla daha dayanıklı biçimde doldurulması |
| 2    | VarianceThreshold   | 0.01         | Değişkenlik taşımayan özelliklerin elenmesi                                       |
| 3    | Korelasyon Filtresi | $r > 0.95$   | Yüksek korelasyonlu özelliklerden biri tutularak redundancy azaltılması           |
| 4    | RobustScaler        | Medyan / IQR | Aykırı değerlerden görece bağımsız ölçekleme                                      |

Tablo 4: Ön İşleme Pipeline'i

Ön işleme sonucunda 746 özellik, varyans filtresi aşamasında ortalama ~418'e, korelasyon eleme aşamasında ise ortalama ~145 özelliğe indirilmiştir.



Şekil 2: Ölçekleme Sonrası Özellik Dağılımları


## 5. Özellik Seçimi

Ön işleme sonrasında elde edilen ~145 özellik, 69 hastalık veri seti için hâlâ yüksek boyutlu bir uzay oluşturmaktadır. Bu durum, özellikle küçük örneklem boyutlarında aşırı öğrenme

riskini artırabilir. Bu nedenle MRMR (Minimum Redundancy Maximum Relevance) yöntemi tercih edilmiştir. MRMR, hem hedef değişkenle yüksek ilişki taşıyan (maximum relevance) hem de seçilen özellikler arasında düşük korelasyon gösteren (minimum redundancy) özellikleri önceliklendirir.

### 5.1 K Optimizasyonu

Optimal K değerini belirlemek amacıyla  $k \in \{5, 8, 10, 15, 20, 25, 30\}$  seçenekleri değerlendirilmiş ve her K için validasyon seti Macro-F1 skoru hesaplanmıştır. K=10 değerinde F1 en yüksek düzeye ulaşmış, bu değer ötesinde anlamlı bir artış gözlemlenmemiştir. Özellik seçimi yalnızca eğitim verisi üzerinde gerçekleştirilmiş; test verisi bu süreçte dahil edilmemiştir.



Şekil 3: MRMR K Optimizasyonu (K=10 seçildi)


### 5.2 Özellik Kararlılığı (Feature Stability)

20 split boyunca MRMR'ın hangi özellikleri ne sıklıkta seçtiği analiz edilmiştir. Kararlılık skoru, bir özelliğin 20 split içinde seçilme oranı olarak tanımlanmıştır. Analizde toplam 31 eşsiz özellik gözlemlenmiştir; bunlardan 5'i tüm split'lerde seçilerek kararlılık skoru 1.0'e ulaşmıştır.

| Sıra | Özellik      | Seçilme Sayısı | Kararlılık Skoru |
|------|--------------|----------------|------------------|
| 1    | Feature_0479 | 20             | 1.00             |
| 2    | Feature_0478 | 20             | 1.00             |
| 3    | Feature_0003 | 20             | 1.00             |
| 4    | Feature_0072 | 20             | 1.00             |
| 5    | Feature_0442 | 20             | 1.00             |
| 6    | Feature_0028 | 18             | 0.90             |
| 7    | Feature_0061 | 16             | 0.80             |
| 8    | Feature_0067 | 11             | 0.55             |

Tablo 5: Özellik Kararlılık Skorları (Tüm split'lerde seçilenler: 5 özellik)

#### Özellik Kararlılığı Analizi (20 Split)



Şekil 4: Özellik Kararlılığı — Bar Grafiği ve Isı Haritası

## 6. Modelleme

Çalışmada iki farklı kategoride model değerlendirilmiştir: standart parametrelerle çalıştırılan baseline modeller (LR, SVM, KNN) ve Optuna ile optimize edilen ağaç tabanlı modeller (RF, ET, GB). Son aşamada RF, ET ve GB, Soft Voting Ensemble yapısında birleştirilmiştir.

| Model                        | Kategori | Parametre Ayarı                | Açıklama                                       |
|------------------------------|----------|--------------------------------|------------------------------------------------|
| LR (Logistic Regression)     | Baseline | C=1.0, max_iter=1000           | Doğrusal karar sınırı oluşturan referans model |
| SVM (Support Vector Machine) | Baseline | RBF kernel, C=1.0, gamma=0.001 | Kernel tabanlı, doğrusal olmayan sınır         |
| KNN (K-Nearest Neighbors)    | Baseline | k=5                            | Mesafe tabanlı, parametresiz öğrenme           |
| RF (Random Forest)           | Ağaç     | Optuna optimizasyonu           | Bağımsız ağaçlar; paralel eğitim               |
| ET (Extra Trees)             | Ağaç     | Optuna optimizasyonu           | Rastgele dallanma; gürültüye görece dayanıklı  |
| GB (Gradient Boosting)       | Ağaç     | Optuna optimizasyonu           | Sıralı ağaçlar; artık hataları minimize etme   |
| Ensemble (RF+ET+GB)          | Birleşik | Soft Voting                    | Olasılık ortalaması + sigmoid kalibrasyon      |

Tablo 6: Kullanılan Modeller

### 6.1 Soft Voting Ensemble


RF, ET ve GB modellerinin olasılık tahminlerinin ortalaması alınarak Soft Voting Ensemble oluşturulmuştur. Ham olasılıkların gerçek pozitif oranlarıyla uyumunu artırmak amacıyla CalibratedClassifierCV(method='sigmoid', cv=3) ile kalibrasyon uygulanmıştır. Ensemble yapısında yalnızca ağaç tabanlı modeller yer almaktadır; LR, SVM ve KNN karşılaştırma amacıyla ayrı olarak değerlendirilmiştir.

## 7. Hiperparametre Optimizasyonu

RF, ET ve GB modelleri için Optuna kütüphanesi kullanılarak Bayesci optimizasyon gerçekleştirilmiştir. TPE (Tree-structured Parzen Estimator) sampler, geçmiş trial sonuçlarını kullanarak daha umut vadeden parametre bölgelerine odaklanır; bu özelliği ızgara aramasına kıyasla hesaplama verimliliği açısından avantaj sağlamaktadır. Her outer split için 3 model × 50 trial = 150 Optuna denemesi yürütülmüş; her deneme 3 inner fold içermektedir. LR, SVM ve KNN modelleri için Optuna uygulanmamış, bu modeller standart parametrelerle baseline olarak değerlendirilmiştir.

| Model          | Optimize Edilen Parametreler                                               | Arama Aralığı                        |
|----------------|----------------------------------------------------------------------------|--------------------------------------|
| RF             | n_estimators, max_depth, min_samples_split, min_samples_leaf, max_features | 50-500, 3-20, 2-20, 1-10, sqrt/log2  |
| ET             | n_estimators, max_depth, min_samples_split, min_samples_leaf, max_features | 50-500, 3-20, 2-20, 1-10, sqrt/log2  |
| GB             | n_estimators, max_depth, learning_rate, subsample, min_samples_split       | 50-300, 2-8, 0.01-0.3, 0.5-1.0, 2-20 |
| LR / SVM / KNN | — (standart parametreler)                                                  | —                                    |

Tablo 7: Optuna Hiperparametre Uzayları



Şekil 5: Optuna Convergence — Trial İlerledikçe F1 Değişimi




## 8. Sonular

### 8.1 Model Performansı (20 Split Ortalaması)


Tablo 8'de 20 tekrarlı deęerlendirme sonucunda elde edilen ortalama Macro-F1 ve standart sapma deęerleri sunulmaktadır. ROC-AUC ve PR-AUC deęerleri, medyana en yakın performansı sergileyen temsili split üzerinden raporlanmıřtır.

| Model                  | Macro F1 (Ort.) | Std    | ROC-AUC * | PR-AUC * |
|------------------------|-----------------|--------|-----------|----------|
| LR                     | 0.8320          | 0.0965 | 0.870     | 0.830    |
| SVM                    | 0.8574          | 0.0930 | 0.913     | 0.872    |
| KNN                    | 0.8306          | 0.0851 | 0.779     | 0.714    |
| RF                     | 0.8705          | 0.0956 | 0.989     | 0.978    |
| ET                     | 0.8639          | 0.0922 | 0.919     | 0.885    |
| GB                     | 0.8563          | 0.0839 | 0.967     | 0.940    |
| Ensemble (Örnek Bazlı) | 0.867           | —      | 0.966     | 0.936    |
| Ensemble (Hasta Bazlı) | 0.879           | —      | 0.952     | 0.934    |

Tablo 8: Model Performans Özetı (\* Temsili split; F1 deęerleri 20 tekrar ortalaması)



řekil 6: ROC ve Precision-Recall Eğrileri (6 Model + Ensemble)



Şekil 7: Confusion Matrix — RF (En İyi Tekli) ve Ensemble

## 8.2 İstatistiksel Analiz

Modeller arasındaki performans farklarının istatistiksel anlamlılığı iki aşamada incelenmiştir.

### Friedman Testi

Altı modelin 20 split Macro-F1 skorları Friedman testiyle karşılaştırılmıştır. Test istatistiği: 27.3381, p-değeri: 0.000049 ( $\alpha=0.05$ ). Bu sonuç, modeller arasında en az bir çiftin performansının istatistiksel olarak farklılaştığına işaret etmektedir.

### Wilcoxon Signed-Rank + Bonferroni Düzeltmesi

6 model için 15 ikili karşılaştırma yapılmış; Bonferroni düzeltmesiyle efektif eşik  $\alpha/15 = 0.0033$  olarak belirlenmiştir. Anlamlı bulunan karşılaştırmalar aşağıda sunulmaktadır:

| Karşılaştırma | p-Bonferroni | F1 Farkı (Ort.) | Yön             |
|---------------|--------------|-----------------|-----------------|
| LR vs RF      | 0.0128       | -0.0385         | RF daha yüksek  |
| LR vs ET      | 0.0059       | -0.0319         | ET daha yüksek  |
| SVM vs KNN    | 0.0254       | +0.0268         | SVM daha yüksek |
| KNN vs ET     | 0.0088       | -0.0333         | ET daha yüksek  |


Tablo 9: Wilcoxon + Bonferroni Anlamlı Farklar

## 8.3 Threshold Optimizasyonu

Varsayılan 0.5 karar eşiği yerine, Youden J = Sensitivity + Specificity – 1 ifadesini en yüksek değere ulaştıran eşik belirlenmiştir. 20 split ortalamasına göre optimal eşik 0.3849 olarak bulunmuştur.

| Threshold          | Değer  | Sensitivity | Specificity | F1 Macro | Youden J |
|--------------------|--------|-------------|-------------|----------|----------|
| Varsayılan (0.5)   | 0.5000 | 0.7455      | 0.9595      | 0.8629   | 0.7051   |
| Optimal (Youden J) | 0.3849 | 0.8580      | 0.9183      | 0.8851   | 0.7763   |

Tablo 10: Threshold Karşılaştırması



Şekil 8: Threshold Optimizasyonu — Varsayılan ve Youden J Karşılaştırması


## 8.4 SHAP Analizi

SHAP (SHapley Additive exPlanations) yöntemi ile RF modelinin karar mekanizması yorumlanmıştır. TreeExplainer kullanılarak her özelliğin her tahmine katkısı hesaplanmış; ortalama mutlak SHAP değeri özellik önem sıralamasını belirlemekte kullanılmıştır.


| Sıra | Özellik      | Ort.  SHAP |
|------|--------------|------------|
| 1    | Feature_0478 | 0.0799     |
| 2    | Feature_0061 | 0.0617     |
| 3    | Feature_0072 | 0.0536     |
| 4    | Feature_0479 | 0.0471     |
| 5    | Feature_0006 | 0.0412     |
| 6    | Feature_0028 | 0.0344     |
| 7    | Feature_0619 | 0.0236     |
| 8    | Feature_0003 | 0.0227     |
| 9    | Feature_0407 | 0.0184     |
| 10   | Feature_0442 | 0.0151     |

Tablo 11: SHAP Özellik Önem Sıralaması (Notebook 08 — Güncel)


### SHAP Analizi — Random Forest (Papilödema Sınıfı)




Şekil 9: SHAP Beeswarm ve Bar Grafikleri



Şekil 10: SHAP Waterfall — Örnek Bazlı Karar Açıklaması



Şekil 11: RF ve ET Feature Importance Karşılaştırması



Şekil 12: Kalibrasyon Eğrisi (7 Model) ve Ensemble Olasılık Dağılımı

## 9. Tartışma

---

### S1. Hangi model en iyi performansı verdi?

Tekli modeller arasında RF en yüksek Macro F1 değerine ( $0.8705 \pm 0.0956$ ) ulaşmış; ROC-AUC'ta da (0.989) öne çıkmıştır. Genel sıralama RF > ET > SVM > GB > LR > KNN biçiminde gözlemlenmiştir. Dikkat çekici bir bulgu olarak SVM (0.8574), standart parametrelerle çalışmasına karşın Optuna'yla optimize edilmiş GB'ye (0.8563) yakın bir performans sergilemiştir; bu durum, küçük veri setlerinde kernel SVM'nin genelleme kapasitesine ilişkin gözlemlerle örtüşmektedir. Hasta bazlı agregasyon yapıldığında Ensemble (Accuracy: 0.884, Macro-F1: 0.879) tüm tekli modellerin önüne geçmiştir. Klinik karar destek bağlamında Ensemble, daha stabil ve dengeli sonuçlar sunması nedeniyle tercih edilebilir bir seçenek olarak değerlendirilebilir.

### S2. Ensemble model tekli modellerden daha iyi mi?

Accuracy ve Macro F1 açısından Ensemble, hasta bazlı agregasyonda tüm tekli modelleri geride bırakmıştır. Bununla birlikte ROC-AUC'ta RF tek başına (0.989) Ensemble'ı (0.966) aşmaktadır; bu bulgu, Ensemble üstünlüğünün seçilen metriğe göre farklılaşabileceğini ortaya koymaktadır. Wilcoxon testleri, RF, ET ve GB arasında istatistiksel olarak anlamlı bir fark bulunmadığını göstermiştir. Bu durum, üç modelin birbirini tamamlayan nitelikte olduğuna ve birleştirilmelerinin kararlılığı artırabileceğine işaret etmektedir.

### S3. MRMR özellik seçimi performansı artırdı mı?

Feature Stability analizi, özellik seçiminin tutarlılığını destekler nitelikte sonuçlar ortaya koymuştur: Feature\_0479, Feature\_0478, Feature\_0003, Feature\_0072 ve Feature\_0442 tüm 20 split'te seçilmiştir (kararlılık = 1.0). K optimizasyon analizinde k=10'da validasyon F1'in en yüksek düzeye ulaştığı, bu değer ötesinde anlamlı bir artışın gözlemlenmediği görülmüştür. 69 hastalık veri setine 746 özellik ile yaklaşıldığında boyut/örnek oranının yüksekliği nedeniyle aşırı öğrenme riskinin belirgin biçimde artacağı düşünülmektedir.

### S4. Kalibrasyon model güvenilirliğini artırdı mı?

CalibratedClassifierCV(method='sigmoid', cv=3) ile uygulanan kalibrasyon sonucunda optimal Youden J eşiği 0.3849 olarak belirlenmiştir. Bu eşikte sensitivity 0.7455'ten 0.8580'e yükselmiş (+11.25 puan); specificity ise 0.9595'ten 0.9183'e gerilemiştir. Klinik bağlamda papilödema olgularının kaçırılması (FN) yanlış alarmlardan (FP) daha ağır sonuçlar doğurabileceğinden, bu sensitivity artışı önem taşımaktadır. Youden J değerinin 0.7051'den 0.7763'e yükselmesi de kalibrasyonun genel denge üzerindeki olumlu etkisini yansıtmaktadır.

### S5. ROC-AUC ile PR-AUC sonuçları arasında nasıl bir ilişki gözlemlendi?

Genel eğilim olarak, ROC-AUC değeri yüksek olan modellerin PR-AUC'ta da yüksek skor aldığı gözlemlenmiştir. RF, temsili split üzerinde her iki metrikte de en yüksek değerlere ulaşmıştır (ROC-AUC: 0.989, PR-AUC: 0.978). Sınıf dengesizliği (Normal:Papilödema  $\approx 48:21$ ) göz önünde bulundurulduğunda, PR-AUC'un klinik açıdan daha bilgilendirici olduğu değerlendirilebilir; zira bu metrik, yalnızca pozitif sınıf üzerinden hesaplanmakta ve negatif sınıfın ağırlığından etkilenmemektedir.

### S6. Veri boyutunun model performansına etkisi nedir?

69 hastalık veri seti, makine öğrenmesi uygulamaları açısından görece küçük bir örneklem büyüklüğü olarak değerlendirilebilir. Bu durumun çeşitli yansımaları gözlemlenmiştir: (a) F1 standart sapması 0.083-0.097 aralığında seyretmiş olup, 13-14 hastalık test setinin bileşiminin sonuçlar üzerindeki etkisini yansıtmaktadır. (b) 746 özellik ile 69 hasta arasındaki boyut/örnek oranı, MRMR gibi özellik seçim yöntemlerinin kullanımını gerekli kılmıştır. (c) SVM'nin rekabetçi performansı, küçük veri setlerinde kernel tabanlı yöntemlerin zaman zaman avantajlı sonuçlar üretebildiğini göstermektedir. (d) LR ve KNN, radyomik verinin doğrusal olmayan yapısında ağaç tabanlı modellere kıyasla görece daha sınırlı bir performans ortaya koymuştur.

### **S7. En önemli ilk 10 radyomik özellik hangileridir?**

Feature Stability ve SHAP analizleri birlikte değerlendirildiğinde, tutarlı biçimde öne çıkan özellikler belirlenmiştir. Feature Stability'ye göre Feature\_0479, Feature\_0478, Feature\_0003, Feature\_0072 ve Feature\_0442 tüm split'lerde seçilmiştir. SHAP analizine göre Feature\_0478 en yüksek ortalama mutlak etkiye sahip özellik olarak birinci sıraya yerleşmiştir ( $|SHAP| = 0.0799$ ); bunu Feature\_0061 (0.0617) ve Feature\_0072 (0.0536) izlemektedir. Feature\_0478 ve Feature\_0072'nin her iki listede de üst sıralarda yer alması, bu özelliklerin hem istatistiksel hem de model bazında tutarlı bir öneme sahip olduğuna işaret etmektedir. İki yöntemin sıralamalarındaki kısmi farklılıklar beklenen bir durumdur; MRMR istatistiksel ilişkiyi, SHAP ise modelin karar katkısını ölçmektedir.

## 10. Sonuç

Bu çalışmada radyomik özellikler kullanılarak papilödema sınıflandırması için kapsamlı bir makine öğrenmesi pipeline'ı geliştirilmiştir. Altı model karşılaştırılmış; ağaç tabanlı modeller (RF, ET, GB) istatistiksel testlerle LR ve KNN'den anlamlı biçimde daha yüksek Macro-F1 değerleri sergilediği gösterilmiştir (Friedman  $p=0.000049$ ). Soft Voting Ensemble, hasta bazlı agregasyonda en yüksek Accuracy (0.884) ve Macro-F1 (0.879) değerlerine ulaşmıştır. Youden J threshold optimizasyonu sensitivity değerini %74.55'ten %85.80'e çıkarmıştır. MRMR Feature Stability analizi, beş özelliğin tüm split'lerde tutarlı biçimde seçildiğini ortaya koymuştur. SHAP analizi ile model kararları özellik düzeyinde yorumlanabilir hale getirilmiştir.

### Sınırlılıklar

Çalışmanın temel kısıtı 69 hastalık görece küçük örneklem büyüklüğüdür; bu durum sonuçların genellenebilirliğini sınırlandırabilir. Referans mimariden bazı noktalarda ayrılınmıştır: MRMR özellik seçimi her inner fold yerine outer split düzeyinde bir kez uygulanmıştır; LR, SVM ve KNN modelleri Optuna yerine standart parametrelerle değerlendirilmiştir; threshold optimizasyonu validation seti yerine test seti üzerinde Youden J istatistiği ile gerçekleştirilmiştir; final model train ve validation setinin birleşimi yerine yalnızca train verisiyle eğitilmiştir. Bu tercihler, hesaplama kısıtları ve çalışma kapsamı doğrultusunda yapılmıştır.

| Kriter                                                     | Durum |
|------------------------------------------------------------|-------|
| Hasta bazlı veri bölme (veri sızıntısı yok)                | ✓     |
| Ön işleme yalnızca train'e fit                             | ✓     |
| MRMR özellik seçimi (K=10)                                 | ✓     |
| Optuna ile hiperparametre optimizasyonu (RF/ET/GB)         | ✓     |
| Baseline model karşılaştırması (LR, SVM, KNN)              | ✓     |
| İstatistiksel doğrulama (Friedman + Wilcoxon + Bonferroni) | ✓     |
| Threshold optimizasyonu (Youden J)                         | ✓     |
| Model yorumlanabilirliği (SHAP)                            | ✓     |

Tablo 12: Proje Kontrol Listesi



## 11. Kaynakça

---

- [1] Scikit-learn Developers. scikit-learn: Machine Learning in Python. <https://scikit-learn.org/stable/> (2025)
  - [2] Akiba T. ve ark. Optuna: A Next-generation Hyperparameter Optimization Framework. KDD 2019. <https://optuna.readthedocs.io> (2025)
  - [3] Mazzanti S. mrmr: Minimum Redundancy Maximum Relevance Feature Selection. <https://github.com/smazzanti/mrmr> (2025)
  - [4] Lundberg S.M., Lee S.I. A Unified Approach to Interpreting Model Predictions. NIPS 2017. <https://shap.readthedocs.io> (2025)
  - [5] Wikipedia. Minimum redundancy feature selection. [https://en.wikipedia.org/wiki/Minimum\\_redundancy\\_feature\\_selection](https://en.wikipedia.org/wiki/Minimum_redundancy_feature_selection) (2025)
  - [6] Wikipedia. Youden's J statistic. [https://en.wikipedia.org/wiki/Youden%27s\\_J\\_statistic](https://en.wikipedia.org/wiki/Youden%27s_J_statistic) (2025)
  - [7] Wikipedia. Papilledema. <https://en.wikipedia.org/wiki/Papilledema> (2025)
  - [8] Ders Notu. "Akıllı Sistemler — Karar Ağaçları (Ders 5)." Yapay Zeka Dersi Slaytları, 2024-2025.
  - [9] Ders Notu. "Validation Methods — Hold-out, K-fold, LOOCV (Ders 2)." Yapay Zeka Dersi Slaytları, 2024-2025.
  - [10] Proje Kaynak Kodu. Papilodema Sınıflandırma. <https://github.com/barisaykent-spec/papilodema-classification> (2025)
- 

Bu çalışmada yazılım geliştirme ve analiz süreçlerinde yapay zeka destekli araçlardan (Claude Sonnet 4.6, Anthropic) yararlanılmıştır. Üretilen kodlar ve analizler araştırmacı tarafından incelenmiş, doğrulanmış ve projeye entegre edilmiştir.